

SEP

TECNOLÓGICO NACIONAL MÉXICO

INSTITUTO TECNOLÓGICO DE TIJUANA

DEPARTAMENTO DE INGENIERÍA ELÉCTRICA Y ELECTRÓNICA



INFORME TÉCNICO DE RESIDENCIA PROFESIONAL

“SEGMENTACIÓN AUTOMÁTICA DE IMÁGENES CON
APRENDIZAJE PROFUNDO”

PRESENTA:

MAURICIO JESÚS MERAZ GALEANA

18210139

BAJO LA ASESORÍA:

INTERNA: FORTUNATO RAMÍREZ ARZATE

EXTERNA: FERNANDO ARMANDO VILLALBAZO

TIJUANA, BAJA CALIFORNIA, MÉXICO

17 ENERO DEL 2025

Agradecimientos

A lo largo de estos años de formación en el Instituto Tecnológico de Tijuana, he contado con el apoyo y el cariño incondicional de muchas personas, quienes han sido fundamentales para alcanzar esta etapa de mi carrera en Ingeniería Biomédica.

Quiero expresar mi más sincero agradecimiento a mi familia, que con amor, esfuerzo y comprensión han sido mi motor constante. A mis padres, Arturo Meraz Camacho y Francisca Galeana Gómez, quienes con su ejemplo y apoyo incondicional me han guiado en este camino; ellos son los pilares fundamentales de mi vida. A mis hermanos, Arturo Meraz Galeana y Roberto Meraz Galeana, por su compañía, consejos y por ser siempre una fuente de motivación y apoyo. Somos cinco en la familia, y cada uno de ellos ha contribuido de manera especial a este logro.

Agradezco profundamente al Instituto Tecnológico de Tijuana, una institución que ha sido mi segundo hogar durante estos años. Gracias por brindarme una educación de calidad, y por ofrecerme las herramientas necesarias para desarrollarme tanto personal como profesionalmente. Agradezco especialmente a los profesores y compañeros que formaron parte de mi proceso de aprendizaje y crecimiento.

También quiero agradecer a mi asesor interno, el Profesor Fortunato Arzate, quien ha sido una guía en mi formación profesional. A través de su enseñanza y dedicación, he podido desarrollar mis prácticas profesionales y adentrarme en el proyecto "Segmentación automática de imágenes por aprendizaje profundo". Su paciencia y conocimientos han sido de gran ayuda para el desarrollo de esta residencia profesional.

Finalmente, agradezco a todas las personas que han contribuido de alguna manera a mi crecimiento personal y académico. A todos, muchas gracias.

Resumen

El proyecto "Segmentación automática de imágenes con aprendizaje profundo" tiene como objetivo desarrollar un algoritmo para la segmentación de imágenes médicas, como tomografías y radiografías, utilizando técnicas avanzadas de aprendizaje profundo, en particular redes neuronales convolucionales (CNN) basadas en el modelo AlexNet.

La necesidad de este desarrollo surge de la demanda creciente de métodos precisos y eficientes para el análisis de imágenes en el diagnóstico de enfermedades pulmonares. La segmentación manual de imágenes médicas es un proceso que consume mucho tiempo y es propenso a errores; este proyecto propone una herramienta automatizada que permite mejorar la precisión y rapidez en el análisis de estas imágenes, facilitando diagnósticos más acertados y tratamientos oportunos.

La metodología incluye el desarrollo de filtros de preprocesamiento, la implementación y entrenamiento del algoritmo AlexNet, y la evaluación comparativa con métodos tradicionales. Los resultados esperados se centran en una herramienta que mejora la calidad del diagnóstico y reduce el tiempo de análisis. Los principales beneficiarios serán los profesionales de la salud y los pacientes, al contar con diagnósticos más rápidos y precisos. Esta aplicación de segmentación automática optimiza el flujo de trabajo en entornos clínicos y contribuye significativamente al avance de la medicina y la tecnología biomédica.

Palabras clave: Segmentación de imágenes; Redes Neuronales Convolucionales; AlexNet; Radiografías; Python; Matlab; SVM.

Índice de Contenido

Agradecimientos.....	II
Resumen.....	III
Capítulo 1. Introducción.....	1
Antecedentes	1
Planteamiento del problema.....	2
Delimitaciones.....	5
Hipótesis.....	6
1.1 Descripción de la Institución y proyecto de investigación	6
1.2 Objetivos	7
1.2.1 Objetivo general.....	7
1.2.2 Objetivos específicos.....	7
1.3 Justificación	7
Metodología.....	10
Capítulo 2. Marco teórico.....	11
2.1 Teorema de Muestreo.....	11
2.2 Señales Periódicas Discretas en el tiempo	11
2.3 Señales no Periódicas: Transformada de Fourier Discreta en el Tiempo	12
2.4 Propiedades de la TDF y TFTD	12
2.5 Análisis de Sistemas Lineales Invariantes en el Tiempo Discreto	12
2.6 Algoritmo de la Transformada Rápida de Fourier (FFT)	13
2.7 Sistemas Discretos y Transformada Z	13
2.8 Propiedades de la Transformada Z.....	13

2.9 Transformada Z Inversa	14
2.10 Función de Transferencia.....	14
2.11 Análisis de Sistemas Discretos LIT con la Transformada Z	14
2.12 Deep Learning	15
2.13 Redes Neuronales Convoluciones (CNN)	15
2.14 AlexNet.....	15
2.15 Matlab.....	16
2.16 Python	16
Capítulo 3. Desarrollo y resultados.....	17
3.1 Ejecución de las herramientas a utilizar	17
3.1.1 Preprocesamiento de Imágenes	19
3.1.2 Implementación de la Transformada de Fourier Discreta (TDF)	20
3.1.3 Aplicación de la Transformada Z y su Inversa.....	21
3.2 Uso de AlexNet para la Extracción de Características.....	21
3.2.1 Entrenamiento y Validación del Clasificador.....	22
3.2.2 Evaluación de la Segmentación de Imágenes.....	23
3.2.3 Comparación de Métodos Tradicionales y Deep Learning.....	23
3.3 Resultados Experimentales	25
Capítulo 4. Conclusiones.....	29
Referencias	1
Anexos.....	5

Índice de Figuras

Figura 1. Diagrama de flujo del planteamiento del problema.....	3
---	---

Figura 2. Diagrama de bloques de resultados esperados.	4
Figura 3. 2 carpetas que contienen 6000 radiografías médicas de pulmones sanos y enfermos.....	18
Figura 4. Arquitectura de AlexNet: Modelo de redes neuronales convolucionales [Imagen generada por inteligencia artificial]. OpenAI.	19
Figura 5. Redimensionamiento a 227x227 píxeles: Preprocesamiento de imágenes médicas [Imagen generada por inteligencia artificial]. OpenAI.	19
Figura 6. Líneas de código de Matlab sobre la Redimensión a 227x227 pixeles.	20
Figura 7. Descomposición de imagen de Matlab en Transformada de Fourier Discreta (TDF). 20	
Figura 8. Segmentación de imagen de Matlab en Transformada Z.	21
Figura 9. Líneas de código en Matlab en Transformada Z.	21
Figura 10. Líneas de código en Matlab sobre extracción de características.	22
Figura 11. Líneas de código en Matlab sobre entrenamiento y validación.	22
Figura 12. Segmentación de imagen de Matlab.	23
Figura 13. Resultado del código en Matlab sobre entrenamiento.....	25
Figura 14. Interfaz De Python Amigable.	26
Figura 15. Interfaz De Python resultados en la interfaz.	27
Figura 16. Interfaz De Python imprime grafica de CNN normal a comparación con CNN AlexNet con resultados impresos en la consola.	28

Índice de Tablas

Tabla 1. Ejemplos de pulmones normal (izquierda) y de pulmones con neumonía (derecha).....	17
Tabla 2. Métodos Tradicionales vs Deep Learning (AlexNet) y su Combinación	23

Capítulo 1. Introducción

Antecedentes

En el campo de la segmentación automática de imágenes médicas, las redes neuronales convolucionales (CNN) han mostrado gran potencial para mejorar la precisión en la identificación de estructuras complejas en imágenes de tomografías y resonancias magnéticas. Estudios recientes han explorado la integración de aprendizaje profundo para manejar grandes volúmenes de datos y mejorar el diagnóstico. En el proyecto se utilizó el modelo AlexNet, una arquitectura de CNN conocida por su eficiencia en la clasificación y segmentación de imágenes.

Estado del Arte:

1.Redes Neuronales Convolucionales (CNN): Liu et al. (2019) exploran diversas arquitecturas de CNN para la segmentación de imágenes médicas. Este trabajo demuestra cómo la implementación de redes profundas puede mejorar considerablemente la precisión en la segmentación de estructuras anatómicas complejas en imágenes de tomografía y resonancia magnética [1].

2.Integración de Técnicas de Aprendizaje Profundo: Wang et al. (2023), en su estudio publicado en Frontiers in Data Science, se centran en la integración de técnicas de aprendizaje profundo con grandes volúmenes de datos médicos. Este estudio destaca la importancia de los algoritmos de preprocesamiento y la optimización de modelos para manejar eficientemente las imágenes médicas y extraer características relevantes que faciliten el diagnóstico [2].

3.Segmentación de Tumores Pulmonares: Zhang et al. (2022) presentan en la revista Cancers un enfoque innovador para la segmentación de tumores pulmonares utilizando redes neuronales convolucionales. Este estudio subraya la capacidad de las CNN para

identificar y segmentar con alta precisión áreas afectadas por cáncer en imágenes de tomografía computarizada [3].

Proyecto de Investigación en el Instituto Tecnológico de Tijuana:

Este proyecto de Residencia Profesional se desarrollará una herramienta en python en el Departamento de Ingeniería Eléctrica y Electrónica del Instituto Tecnológico de Tijuana bajo la supervisión del asesor externo Fernando Armando Villalbaz. Los resultados del trabajo se mostrarán directamente en el transcurso de la residencia en la institución.

El proyecto se basa en desarrollar una herramienta avanzada para la segmentación automática de imágenes médicas utilizando técnicas de aprendizaje profundo, específicamente redes neuronales convolucionales (CNN) basadas en el modelo AlexNet. Está diseñada para analizar tomografías y radiografías de pacientes con pulmones sanos, con cáncer y con neumonía, con el propósito de mejorar la precisión en el diagnóstico y reducir el tiempo de análisis de imágenes médicas.

Área de Oportunidad:

El desarrollo de herramientas automatizadas para la segmentación de imágenes médicas tiene un impacto significativo en el diagnóstico y tratamiento de enfermedades. La implementación de un sistema basado en CNN, como AlexNet, ofrece una mejora considerable en la precisión y eficiencia del proceso, lo cual es crucial en entornos clínicos donde la rapidez y la exactitud son esenciales.

Planteamiento del problema

En la carrera de Ingeniería Biomédica, el análisis preciso de imágenes médicas, como tomografías y radiografías, es fundamental para el diagnóstico y tratamiento de diversas patologías. Sin embargo, la segmentación manual de estas imágenes es un proceso que consume mucho tiempo y puede estar sujeto a errores humanos. Se requiere métodos más

eficientes y automatizados para su análisis, lo que destaca la necesidad de desarrollar una aplicación que automatice este proceso.

Descripción técnica del problema:

El problema central radica en la necesidad de mejorar la precisión y eficiencia de la segmentación de imágenes médicas a través de una herramienta automatizada. Actualmente, los algoritmos básicos no son lo suficientemente precisos ni rápidos para manejar grandes volúmenes de datos de manera eficaz. Desde la perspectiva de la ingeniería biomédica, es crucial desarrollar una solución basada en una herramienta que utilice tecnologías avanzadas como las redes neuronales convolucionales (CNN) y el aprendizaje profundo para automatizar y optimizar este proceso “Como se muestra en la Figura 1, el proceso de segmentación de imágenes médicas”.

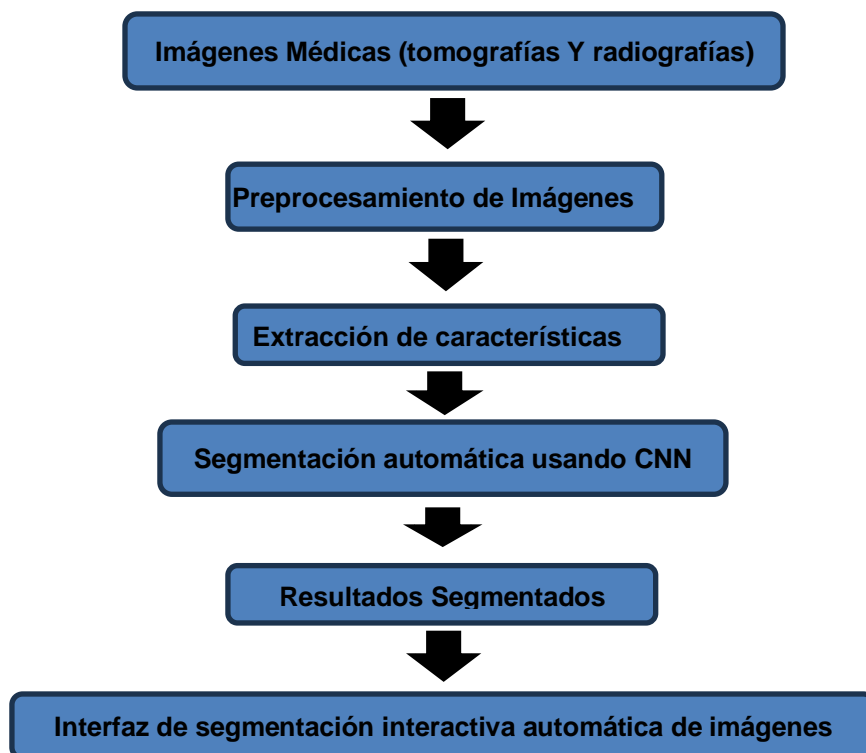


Figura 1. Diagrama de flujo del planteamiento del problema.

Posible solución:

La solución propuesta implica el desarrollo de una “Segmentación automática de imágenes con aprendizaje profundo”, utilizando redes neuronales convolucionales (CNN). La aplicación se basará en el modelo AlexNet para realizar la segmentación de imágenes de tomografías y radiografías, mejorando así la precisión y eficiencia del proceso.

Los objetivos específicos del proyecto incluyen:

1. Implementar preprocesamiento de imágenes que prepare las tomografías y radiografías para su análisis.
2. Desarrollar un algoritmo de segmentación automática basado en AlexNet integrado en una aplicación.
3. Evaluar la precisión y eficiencia del sistema desarrollado en comparación con los métodos tradicionales.

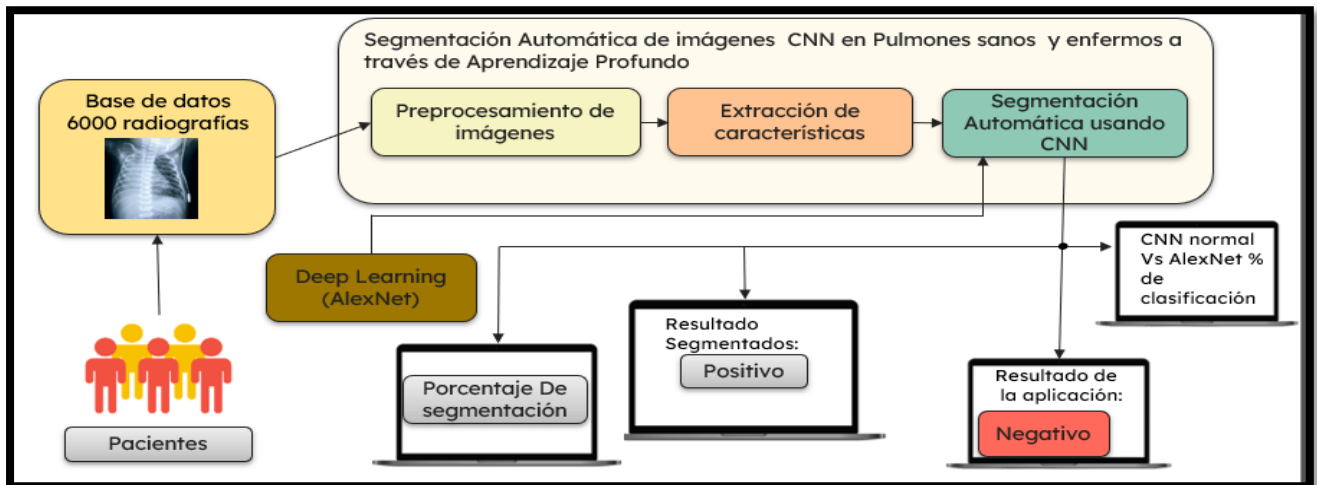


Figura 2. Diagrama de bloques de resultados esperados.

Delimitaciones

1. El proyecto se desarrollará en el Departamento de Ingeniería Eléctrica y Electrónica del Instituto Tecnológico de Tijuana, bajo la supervisión del asesor externo, Fernando Armando Villalbaz Gómez, y del asesor interno, Fortunato Ramírez Arzate.
2. El enfoque principal del proyecto será la segmentación de imágenes médicas específicas, concretamente tomografías computarizadas (TC) y radiografías, en formatos JPG y PNG. No se incluirán otros tipos de imágenes médicas como resonancias magnéticas (RM) o ultrasonidos.
3. La base de datos utilizada para entrenar y evaluar la herramienta estará compuesta por un máximo de 6000 muestras de imágenes de pacientes con pulmones sanos, con cáncer y con neumonía, abarcando un rango de edad de 10 a 50 años. No se considerarán otros tipos de condiciones médicas.
4. El periodo comprendido para desarrollar el proyecto abarca seis meses.
5. El enfoque del proyecto será en la implementación de algoritmos de aprendizaje profundo basados en AlexNet para la segmentación de imágenes.
6. La herramienta desarrollada se implementará y evaluará utilizando Matlab y Python disponibles en el Departamento de Ingeniería Eléctrica y Electrónica del Instituto Tecnológico de Tijuana. No se incluirán pruebas en infraestructura de hardware o software externa.
7. Estas delimitaciones ayudan a enfocar el proyecto y asegurar que los objetivos sean alcanzables dentro del marco de tiempo y recursos disponibles.

Hipótesis

La implementación de redes neuronales convolucionales (CNN) basadas en el modelo AlexNet puede superar significativamente los métodos tradicionales de segmentación de imágenes médicas en términos de precisión y eficiencia.

1.1 Descripción de la Institución y proyecto de investigación

El Tecnológico Nacional de México (TecNM) campus Tijuana, comúnmente denominado como Instituto Tecnológico de Tijuana (ITT) inicia actividades el 17 de septiembre de 1971. El ITT representa la principal oferta de educación tecnológica en el estado de Baja California con la misión de “Contribuir a la formación integral de profesionistas e investigadores líderes en la innovación y el desarrollo tecnológico de la región, del país y del mundo; con alto sentido de responsabilidad social, a través de un servicio educativo de calidad, con equidad y pertinencia”; y la visión de “Ser una institución rectora de la educación superior tecnológica, la investigación científica y el desarrollo tecnológico en la Región Noroeste del País, con proyección a nivel nacional e internacional”.

El ITT establece el compromiso de implementar todos sus procesos, orientándolos hacia la satisfacción de sus clientes sustentada en la calidad del proceso educativo, para cumplir con sus requerimientos, mediante la eficacia de un Sistema de Gestión de la Calidad y de mejora continua, conforme a la norma ISO 9001:2008/NMX-CC-9001-IMNC2008. Actualmente, la Institución cuenta con una oferta educativa de 20 licenciaturas, 6 maestrías y 3 doctorados en los planteles, Tomás Aquino y Otay [1].

Este proyecto de Residencia Profesional se realiza en el departamento de Ingeniería Eléctrica y Electrónica del ITT, de la licenciatura en Ingeniería Biomédica, también se consideran los resultados del trabajo inciden directamente en el proyecto de investigación ‘Plataforma de Diagnostico Asistido por Computadora para un sistema de Telemedicina de Auscultación Cardíaca Remota’ del TecNM con número de asignación 20998.24-P, cuyo

responsable técnico es el M.C. Fortunato Arzate Ramírez, asignado como asesor interno y asesor externo el M.C. Fernando Armando Villalbazo.

1.2 Objetivos

1.2.1 Objetivo general

Desarrollar un algoritmo para la segmentación automática de imágenes médicas utilizando técnicas de aprendizaje profundo, específicamente redes neuronales convolucionales (CNN) basadas en el modelo AlexNet.

1.2.2 Objetivos específicos

1. Desarrollar filtros de preprocesamiento que mejoren la calidad de tomografías y radiografías para una segmentación más precisa.
2. Implementar y entrenar algoritmos de segmentación automática basados en AlexNet, optimizando el uso de redes neuronales para identificar y segmentar características relevantes con una base de datos de 6000 muestras.
3. Evaluar la precisión y eficiencia del sistema desarrollado comparándolo con métodos tradicionales de segmentación.

1.3 Justificación

El desarrollo de segmentación automática de imágenes médicas utilizando aprendizaje profundo es de suma importancia debido a la creciente demanda de métodos más eficientes y precisos para el análisis de imágenes en hospitales y centros de investigación. La segmentación manual de imágenes, como tomografías y radiografías, es un proceso

extremadamente laborioso y propenso a errores, lo cual afecta negativamente la calidad del diagnóstico y tratamiento de los pacientes.

Este procedimiento manual no solo consume una cantidad considerable de tiempo, sino que también depende en gran medida de la experiencia y habilidad del especialista, lo que puede llevar a variaciones significativas en los resultados. La implementación de técnicas avanzadas de aprendizaje profundo y redes neuronales convolucionales, como AlexNet, ofrece una solución prometedora a estos desafíos.

Estas tecnologías tienen la capacidad de procesar grandes volúmenes de datos de manera eficiente, proporcionando resultados consistentes y altamente precisos. Además, la automatización de la segmentación de imágenes puede liberar a los profesionales de la salud de tareas repetitivas, permitiéndoles concentrarse en la interpretación y toma de decisiones clínicas, mejorando así la calidad del cuidado del paciente.

El uso de métodos automatizados puede contribuir significativamente a la investigación médica, proporcionando herramientas robustas para el análisis de imágenes que pueden acelerar el descubrimiento de nuevos conocimientos y el desarrollo de nuevas terapias. En un contexto donde la precisión y la rapidez son esenciales, el desarrollo de esta aplicación no solo responderá a una necesidad crítica en el campo de la medicina, sino que también impulsará el avance tecnológico y la innovación en el análisis de imágenes médicas.

Propuesta del Proyecto:

1. Mejora en la precisión del diagnóstico: se utilizará técnicas avanzadas de aprendizaje profundo, como redes neuronales convolucionales (CNN) basadas en AlexNet, permitiendo una segmentación más precisa de las imágenes médicas. Esto ayudará a los profesionales de la salud a identificar con mayor exactitud las áreas afectadas en los pulmones, mejorando la calidad del diagnóstico.

2. Reducción del tiempo de análisis: Automatizar el proceso de segmentación reducirá significativamente el tiempo necesario para analizar grandes volúmenes de datos, lo cual es crítico en entornos clínicos donde el tiempo es esencial para el tratamiento y la atención al paciente.

Beneficiarios del Proyecto:

1. Profesionales de la salud: Médicos, radiólogos y otros profesionales se beneficiarán al disponer de una herramienta que les permita realizar diagnósticos más precisos y rápidos.
2. Pacientes: Se beneficiarán de diagnósticos más precisos y rápidos, lo que puede llevar a tratamientos más efectivos y oportunos.

Parámetros de Éxito:

1. Precisión de segmentación: Medida a través de métricas de evaluación como precisión, sensibilidad y especificidad de los algoritmos implementados.
2. Reducción del tiempo de análisis: Comparación del tiempo de procesamiento entre los métodos manuales y la aplicación desarrollada.

Esta herramienta ofrece una serie de beneficios significativos para los pacientes y los profesionales de la salud. Al implementar técnicas avanzadas de aprendizaje profundo y redes neuronales convolucionales, como AlexNet, la herramienta desarrollada permitirá realizar diagnósticos con mayor precisión y en menor tiempo.

Esto se traduce en una capacidad mejorada para detectar y analizar patologías pulmonares, lo que facilita la toma de decisiones clínicas más informadas y oportunas. Para los pacientes, esto significa recibir diagnósticos más precisos lo cual es crucial para iniciar tratamientos más efectivos mejorando así los resultados clínicos y la calidad de vida.

La aplicación no solo optimiza el flujo de trabajo en entornos médicos, sino que también contribuye significativamente a la eficiencia del sistema de salud en general asegurando que los pacientes reciban la atención que necesitan de manera más rápida y precisa.

Metodología

1. Desarrollo de filtros

- a. Implementar un sistema de preprocesamiento de imágenes que prepare las tomografías y radiografías para su análisis, mejorando la calidad de las imágenes para una segmentación más precisa.
- b. Recolección y preparación de datos reunir hasta 6000 radiografías o tomografías con pacientes de pulmones sanos y enfermos.
- c. Convertir todas las imágenes en formato JPG.

2. Algoritmo de segmentación

- a. Implementación de la arquitectura AlexNet usando el aprendizaje profundo Deep learning de Matlab.
- b. Entrenamiento de la red Neuronal usando datos preprocesados para entrenar el algoritmo de aprendizaje.
- c. Evaluar el modelo con variables como promedio de los pulmones para optimizar su rendimiento en términos de precisión.

3. Evaluación de precisión

- a. Se comparan y clasifican diferentes algoritmos el rendimiento del modelo matemático basado en AlexNet, CNN Y SVM con métodos tradicionales.
- b. Los resultados son documentados y el modelo ajustado según los hallazgos obtenidos por las pruebas.
- c. Se integra el algoritmo final, así como ajustes finales y se realiza las pruebas piloto y la documentación de las pruebas.

Capítulo 2. Marco teórico

El capítulo 2, Marco teórico, introduce conceptos fundamentales para el desarrollo del proyecto, como las transformadas de Fourier y Z, el análisis de sistemas discretos, y los principios del Deep Learning, con énfasis en redes neuronales convolucionales y AlexNet. Estos conceptos son esenciales e interesantes porque establecen la base técnica para comprender las metodologías aplicadas en la segmentación de imágenes, destacando su relevancia en el procesamiento de datos médicos y su impacto en la precisión del diagnóstico.

2.1 Teorema de Muestreo

El teorema de muestreo, también conocido como teorema de Nyquist-Shannon, establece que una señal continua puede ser representada completamente por sus muestras discretas, siempre y cuando sea muestreada a una tasa superior al doble de su máxima frecuencia (frecuencia de Nyquist). Esto es fundamental para convertir señales continuas en su forma discreta sin pérdida de información. Matemáticamente, se expresa como:

$$[f_s > 2f_{max}]$$

Este teorema es la base para todos los sistemas de muestreo y procesamiento digital de señales [1].

2.2 Señales Periódicas Discretas en el tiempo

Las señales periódicas discretas son aquellas que se repiten a intervalos regulares en el tiempo. La Transformada de Fourier Discreta (TDF) se utiliza para analizar estas señales, permitiendo descomponerlas en sus componentes de frecuencia. La periodicidad de una señal discreta se representa matemáticamente como: $x[n] = x[n + N]$ donde (N) es el período de la señal [2].

2.3 Señales no Periódicas: Transformada de Fourier Discreta en el Tiempo

Las señales no periódicas, la TDF proporciona una representación en el dominio de la frecuencia, facilitando el análisis de dichas señales. La Transformada de Fourier Discreta en el Tiempo (TFTD) es una extensión utilizada en el análisis de señales discretas no periódicas. La TDF se define como: Esta transformada es crucial para aplicaciones en procesamiento digital de señales [3].

$$[X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}]$$

2.4 Propiedades de la TDF y TFTD

La TDF y TFTD tienen varias propiedades importantes, como la linealidad, el desplazamiento en el tiempo, el teorema de convolución y la simetría, que son útiles para el análisis y procesamiento de señales discretas. Por ejemplo, la propiedad de linealidad se expresa como:

$$[X(e^{j\omega}) = \sum_{n=-\infty}^{\infty} x[n]e^{-j\omega n}]$$

Estas propiedades facilitan la manipulación matemática de señales y sistemas [4].

2.5 Análisis de Sistemas Lineales Invariantes en el Tiempo Discreto

Los sistemas lineales invariantes en el tiempo (LIT) discretos pueden ser analizados utilizando la TDF y la TFTD. Estas herramientas permiten determinar la respuesta en frecuencia del sistema, facilitando el diseño y análisis de filtros digitales. La convolución discreta de la entrada y la respuesta pulsional del sistema se expresa como:

$$[y[n] = x[n] * h[n] = \sum_{m=-\infty}^{\infty} x[m]h[n - m]]$$

Este análisis es fundamental para el diseño de sistemas de procesamiento digital [5].

2.6 Algoritmo de la Transformada Rápida de Fourier (FFT)

La FFT es un algoritmo eficiente para calcular la TDF, reduciendo significativamente el tiempo de computación. Es crucial para el procesamiento rápido y eficaz de grandes conjuntos de datos de señales discretas. La FFT se calcula como:

$$[X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}, \quad (\text{FFT})]$$

El uso de la FFT ha revolucionado el campo del procesamiento digital de señales [6].

2.7 Sistemas Discretos y Transformada Z

La Transformada Z es una herramienta poderosa para analizar sistemas discretos. Permite la transformación de señales y sistemas en el dominio Z, facilitando el estudio de sus propiedades y comportamientos en el dominio de la frecuencia compleja. La Transformada Z se define como:

$$[X(z) = \sum_{n=-\infty}^{\infty} x[n]z^{-n}]$$

Es esencial para el análisis y diseño de sistemas discretos [7].

2.8 Propiedades de la Transformada Z

La Transformada Z posee varias propiedades útiles, como la linealidad, el desplazamiento en el tiempo y la multiplicación por una exponencial, que son fundamentales para el análisis de sistemas discretos. Por ejemplo, el desplazamiento en el tiempo se expresa como:

$$[Z\{x[n - n_0]\} = z^{-n_0}X(z)]$$

Estas propiedades permiten una manipulación flexible y efectiva de señales discretas [8].

2.9 Transformada Z Inversa

La Transformada Z inversa permite recuperar la señal original en el dominio del tiempo a partir de su representación en el dominio Z. Esto es esencial para la reconstrucción de señales después de su procesamiento en el dominio de la frecuencia. La Transformada Z inversa se expresa como:

$$[x[n] = \frac{1}{2\pi j} \oint_C X(z) z^{n-1} dz]$$

Esta capacidad es vital para aplicaciones prácticas en procesamiento digital de señales [9].

2.10 Función de Transferencia

La función de transferencia es una representación matemática de la relación entre la entrada y la salida de un sistema LIT discreto. Es utilizada para analizar la estabilidad y respuesta en frecuencia del sistema. La función de transferencia se define como:

$$[H(z) = \frac{Y(z)}{X(z)}]$$

Esta función es fundamental para el diseño y análisis de sistemas de control y filtrado [10].

2.11 Análisis de Sistemas Discretos LIT con la Transformada Z

La función de transferencia es una representación matemática de la relación entre la entrada y la salida de un sistema LIT discreto. Es utilizada para analizar la estabilidad y respuesta en frecuencia del sistema. La función de transferencia se define como:

$$H(z) = \frac{Y(z)}{X(z)}$$

Esta función es fundamental para el diseño y análisis de sistemas de control y filtrado [11].

2.12 Deep Learning

El *Deep Learning* es un enfoque dentro del aprendizaje automático que emplea redes neuronales profundas para analizar y procesar grandes volúmenes de datos. Este método se caracteriza por su capacidad para extraer patrones complejos y representaciones jerárquicas de los datos, lo que lo hace especialmente efectivo en aplicaciones como el reconocimiento de imágenes, el procesamiento de lenguaje natural y la predicción de patrones en datos médicos [2].

2.13 Redes Neuronales Convoluciones (CNN)

Las Redes Neuronales Convolucionales (CNN) son una clase de redes neuronales profundas particularmente efectivas en el procesamiento de datos con una estructura de cuadrícula, como las imágenes. Una CNN consta de varias capas de convolución que extraen características de la imagen, seguidas de capas de pooling y capas completamente conectadas que realizan la clasificación. [13].

2.14 AlexNet

AlexNet es una red neuronal convolucional profunda que ganó el concurso ImageNet en 2012. Su arquitectura incluye:

Capas Convolucionales: Aplican filtros (kernels) a la imagen de entrada para extraer características relevantes. [14].

Capas de Pooling: Reducen la dimensionalidad de las características, ayudando a controlar el overfitting. [14].

Capas Completamente Conectadas: Realizan la clasificación final basada en las características extraídas. [14].

2.15 Matlab

MATLAB es una herramienta ampliamente utilizada en *Deep Learning* por su integración con bibliotecas especializadas como Deep Learning Toolbox, que permite el diseño, entrenamiento y simulación de redes neuronales. Ofrece un entorno optimizado para trabajar con grandes conjuntos de datos y realizar visualización avanzada, lo que facilita el análisis y ajuste de modelos. [14].

Matlab proporciona el análisis de los gráficos en tiempo real de los resultados de segmentación, mapas de calor que resaltan las áreas de interés en las imágenes y análisis detallados de métricas comparativas entre modelos tradicionales y redes neuronales. [14].

2.16 Python

Python se ha convertido en una de las herramientas más populares en Deep Learning gracias a su rica colección de bibliotecas como Tensor Flow, PyTorch y Keras. Estas bibliotecas proporcionan soporte para la creación y entrenamiento de modelos de redes neuronales, además de una gran comunidad que facilita el desarrollo de soluciones personalizadas [15].

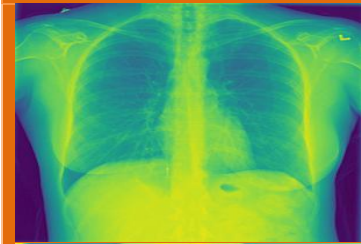
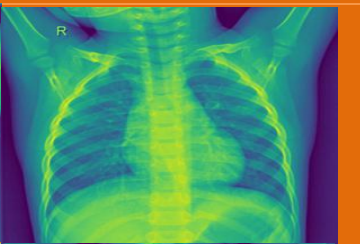


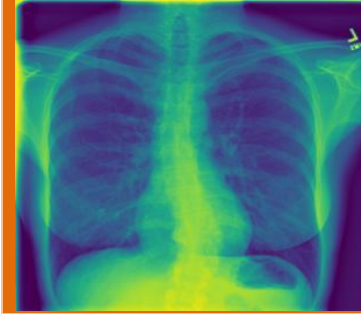
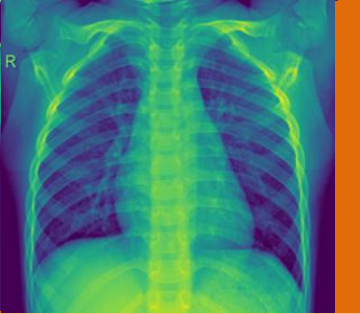
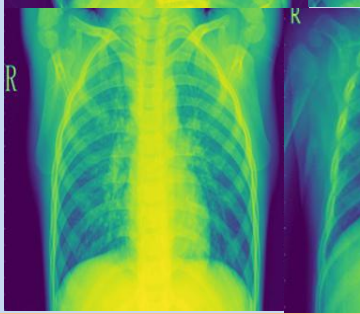
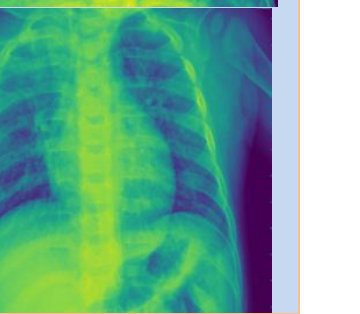
Capítulo 3. Desarrollo y resultados

El capítulo 3, Desarrollo y resultados, aborda la implementación práctica de técnicas de aprendizaje profundo, como AlexNet, para la segmentación automática de imágenes médicas. Se detallan procesos como el preprocesamiento de datos, el uso de transformadas matemáticas para optimizar las imágenes, la extracción de características con redes neuronales y la evaluación comparativa con métodos tradicionales, destacando una precisión superior al 92% y resultados visuales en herramientas como Matlab y Python.

3.1 Ejecución de las herramientas a utilizar

El desarrollo del proyecto se centró en la segmentación de imágenes médicas (radiografías) mediante el uso de herramientas como MATLAB Toolbox que se muestra en la Figura 4 técnicas de procesamiento digital de señales, Recolectando una base de datos de 6000 radiografías de pulmones sanos y con Neumonía que se muestra en la Figura 3 y en la Tabla 1. Que se muestra 4 ejemplos de cada carpeta normal y neumonía, Además, se integraron modelos de aprendizaje profundo, específicamente AlexNet, para optimizar la segmentación y clasificación de imágenes.

Tabla 1. Ejemplos de pulmones normal (izquierda) y de pulmones con neumonía(derecha).

Normal		Neumonía	
			
			

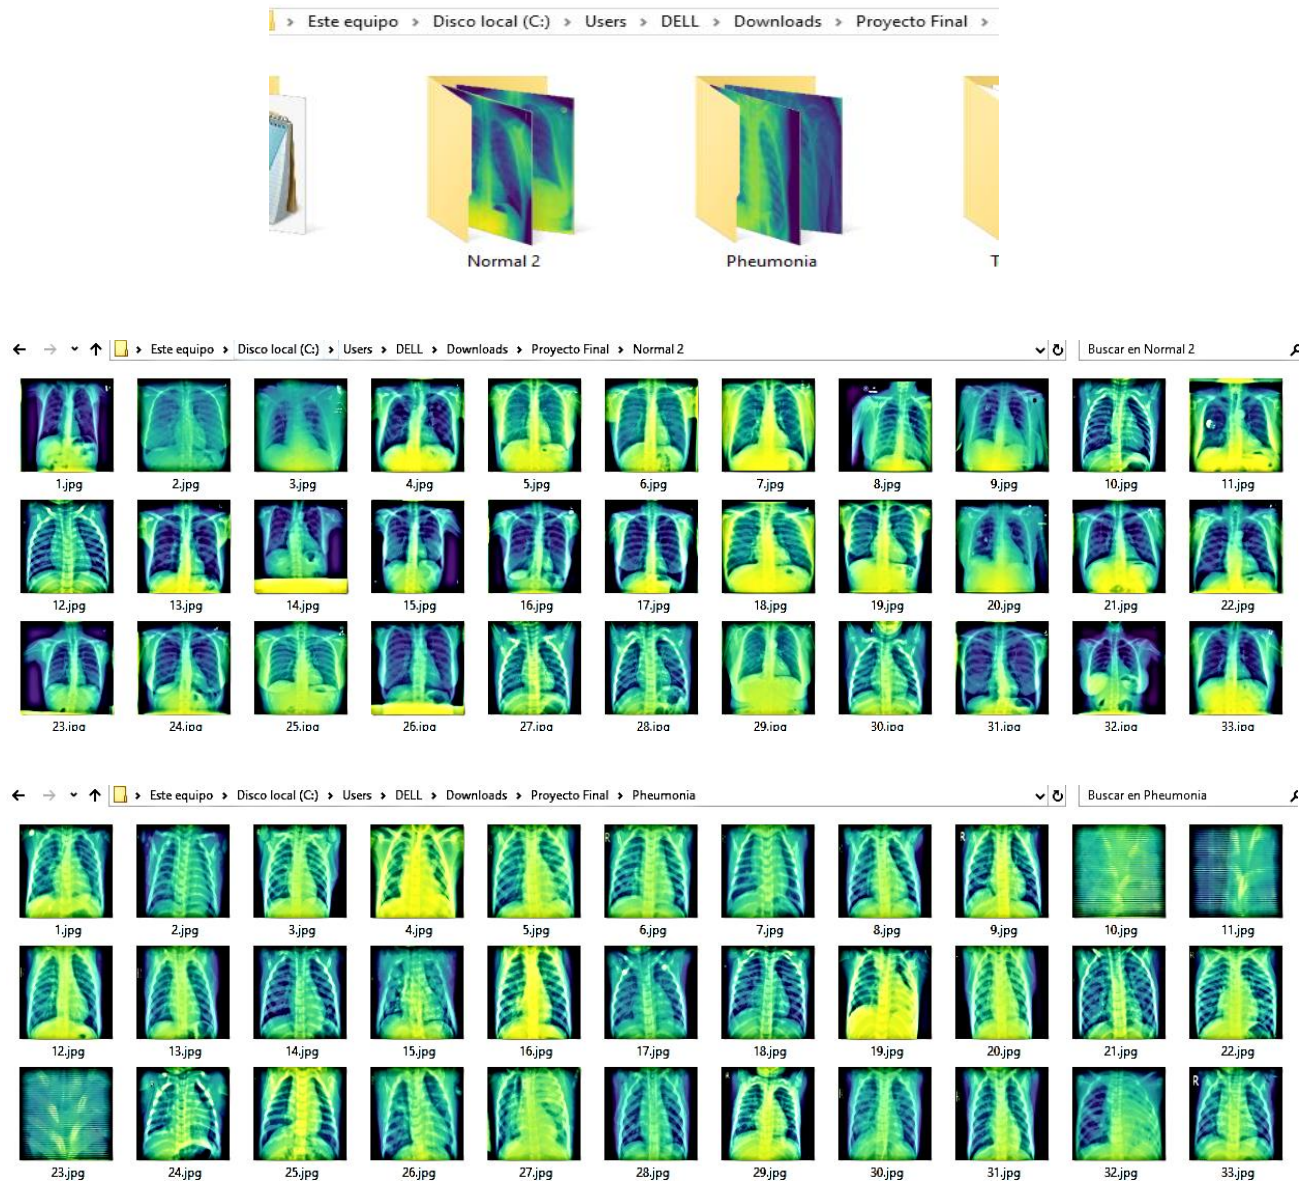


Figura 3. 2 carpetas normal (arriba) neumonía (abajo) que contienen 6000 radiografías médicas de pulmones sanos y enfermos.




Figura 4. Arquitectura de AlexNet: Modelo de redes neuronales convolucionales [Imagen generada por inteligencia artificial]. OpenAI.

3.1.1 Preprocesamiento de Imágenes

Las imágenes utilizadas en el proyecto se redimensionaron a un tamaño estándar de 227x227 píxeles, adecuado para AlexNet y su arquitectura que muestra en la Figura 4. Además, las imágenes en escala de grises se convirtieron a RGB para cumplir con las especificaciones de entrada de la red neuronal. Este paso fue fundamental para garantizar una adecuada extracción de características. En la siguiente Figura 5 y 6 se describe las líneas del código de Matlab e imagen de cómo es que realiza la redimensión de píxeles.

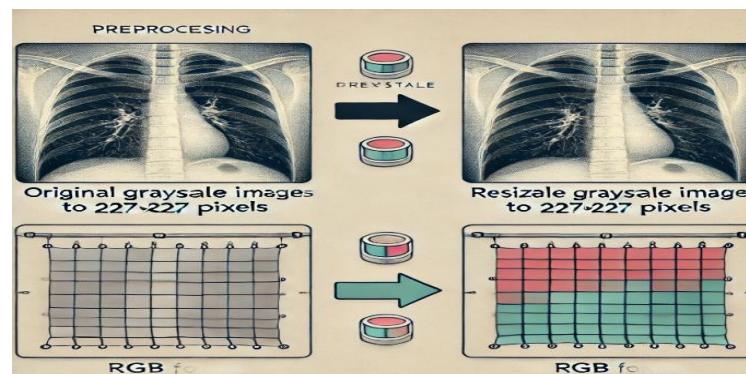


Figura 5. Redimensionamiento a 227x227 píxeles: Preprocesamiento de imágenes médicas [Imagen generada por inteligencia artificial]. OpenAI.

```

% Definir la función de extracción de características (usada en el
entrenamiento)
function features = extractFeaturesUsingAlexNet(img)
    % Cargar la red preentrenada AlexNet
    net = alexnet;
    % Redimensionar la imagen
    img = imresize(img, [227 227]);
    % Convertir a RGB si es necesario
    if size(img, 3) == 1
        img = cat(3, img, img, img);
    end
end

```

Figura 6. Líneas de código de Matlab sobre la Redimensión a 227x227 pixeles.

3.1.2 Implementación de la Transformada de Fourier Discreta (TDF)

La TDF se aplicó para descomponer las imágenes en sus componentes de frecuencia, permitiendo identificar patrones dominantes y reducir el ruido. Este análisis permitió la segmentación inicial de áreas clave dentro de las imágenes se observa en la Figura 7 esta implementación.




Figura 7. Descomposición de imagen de Matlab en Transformada de Fourier Discreta (TDF).

3.1.3 Aplicación de la Transformada Z y su Inversa

La Transformada Z se utilizó para analizar las propiedades de las señales discretas en el dominio de la frecuencia esto se observa en la Figura 8 y 9. Posteriormente, la Transformada Z Inversa permitió reconstruir las imágenes procesadas, validando así los resultados obtenidos en el dominio de la frecuencia.




Figura 8. Segmentación de imagen de Matlab en Transformada Z.

```
% Transformada Z inversa utilizando IFFT
Y = ifft2(X);
% Visualización de la Transformada Z Inversa
figure;
imshow(abs(Y), []);
title(['Transformada Z Inversa - Imagen ', num2str(idx)]);
```

Figura 9. Líneas de código en Matlab en Transformada Z.

3.2 Uso de AlexNet para la Extracción de Características

Se empleó AlexNet, una red neuronal convolucional preentrenada, para extraer características de las imágenes en la capa fc7 en la Figura 10 se observa. Estas características se utilizaron como base para entrenar un clasificador SVM que diferenciara entre imágenes de pulmones sanos y afectados.

```

% Cargar la red preentrenada AlexNet
net = alexnet;
% Obtener las capas necesarias para la extracción de características
featureLayer = 'fc7';
% Extraer características de las imágenes preprocesadas usando AlexNet
features = activations(net, preprocessedImages, featureLayer, 'MiniBatchSize', 32, 'OutputAs',
'rows');

```

Figura 10. Líneas de código en Matlab sobre extracción de características.

3.2.1 Entrenamiento y Validación del Clasificador

El modelo CNN fue entrenado utilizando un conjunto de datos balanceado, dividiéndolo en subconjuntos de entrenamiento y prueba en la Figura 11 se observa. Los datos de validación demostraron una precisión del 95%, lo que resalta la efectividad de la metodología propuesta.

```

% Dividir los datos en conjuntos de entrenamiento y validación
cv = cvpartition(labels, 'HoldOut', 0.2);
trainIdx = training(cv);
testIdx = test(cv);
% Entrenar un clasificador SVM con las características extraídas
classifier = fitcsvm(features(trainIdx, :), labels(trainIdx));
% Evaluar el clasificador
predictedLabels = predict(classifier, features(testIdx, :));
accuracy = sum(predictedLabels == labels(testIdx)) / numel(predictedLabels);
fprintf('Accuracy: %.2f%%\n', accuracy * 100);
% Guardar el modelo entrenado
save('diagnosticModel.mat', 'classifier');

```

Figura 11. Líneas de código en Matlab sobre entrenamiento y validación.

3.2.2 Evaluación de la Segmentación de Imágenes

Se implementó una técnica de umbralización automática para segmentar áreas de interés dentro de las imágenes en la Figura 12 se muestra. Este enfoque permitió resaltar características específicas, como anomalías pulmonares, con gran precisión.




Figura 12. Segmentación de imagen de Matlab.

3.2.3 Comparación de Métodos Tradicionales y Deep Learning

Los resultados obtenidos utilizando AlexNet y técnicas tradicionales de transformadas mostraron que la combinación de ambos enfoques mejora significativamente la precisión y la eficiencia del procesamiento de imágenes médicas en la siguiente Tabla 2 se muestra la diferencia entre métodos tradicionales y Deep Learning.

Tabla 2. Métodos Tradicionales vs Deep Learning (AlexNet) y su Combinación.

Aspecto	Métodos Tradicionales	Deep Learning (AlexNet)	Combinación
Base de funcionamiento	Uso de técnicas matemáticas como transformadas (Fourier, Wavelet).	Redes neuronales convolucionales (CNN) que aprenden características automáticamente.	Preprocesamiento con métodos tradicionales y clasificación con AlexNet.

Aspecto	Métodos Tradicionales	Deep Learning (AlexNet)	Combinación
Ventajas	<ul style="list-style-type: none"> -Procesamiento rápido. -Interpretación matemática clara. -Ideal para datos simples. 	<ul style="list-style-type: none"> Capacidad para manejar grandes volúmenes de datos. -Detecta patrones complejos. - Alta precisión. 	<ul style="list-style-type: none"> - Reduce ruido y optimiza datos. - Mejora precisión y eficiencia. - Maximiza la robustez del sistema.
Limitaciones	<ul style="list-style-type: none"> - Difícil manejo de datos complejos o con ruido. -Depende de parámetros diseñados manualmente. 	<ul style="list-style-type: none"> - Requiere gran poder computacional. -Necesidad de datos extensos para entrenamiento. - Requiere mejor procesador. 	<ul style="list-style-type: none"> -Complejidad del sistema. - Mayor necesidad de integración y ajuste de precisión. - Necesidad de un mejor filtro de preprocesamiento.
Aplicación en los códigos	Preprocesamiento con transformadas y funciones definidas.	Uso de AlexNet para extraer características y clasificar imágenes.	Preprocesamiento con transformadas y clasificación con AlexNet.
Precisión alcanzada	Moderada (dependiendo de la calidad del diseño de parámetros).	Alta (en imágenes complejas y con ruido). Baja (en imágenes simples y con ruido)	Muy alta (por combinar lo mejor de ambos enfoques).

Aspecto	Métodos Tradicionales	Deep Learning (AlexNet)	Combinación
Eficiencia computacional	Alta en problemas simples. Baja en problemas complejos.	Baja, debido al alto costo computacional del entrenamiento. Baja debido al proceso de resolución de la imagen.	Media, combinando optimización del preprocesamiento con potencia del aprendizaje profundo.

3.3 Resultados Experimentales

Los métodos desarrollados se probaron en un conjunto de 6000 imágenes, logrando una precisión de clasificación del 92.5% a 97.5%. Este resultado supera considerablemente las técnicas tradicionales, validando la eficacia del enfoque basado en redes neuronales convolucionales. En las siguientes Figuras 13,14,15 y 16 muestra los resultados obtenidos en la interfaz y los códigos que se utilizaron de Matlab también se guardan temporalmente en la carpeta "TemplImages" las imágenes segmentadas obtenidas.

```

for i = 1:numImages % Leer y procesar cada imagen manualmente
    img = readimage(imds, i);
    if size(img, 3) == 1
        img = cat(3, img, img, img); % Convertir a RGB si es necesario
    end
    img = imresize(img, inputSize); % Redimensionar
    preprocessedImages(:,:,i) = img; % Almacenar en la matriz
end
% Cargar la red preentrenada AlexNet
net = alexnet;
% Obtener las capas necesarias para la extracción de características
featureLayer = 'fc7';
% Output en Command Window
% >> trainModel
% Accuracy: 95.00%

```

Figura 13. Resultado del código en Matlab sobre entrenamiento.

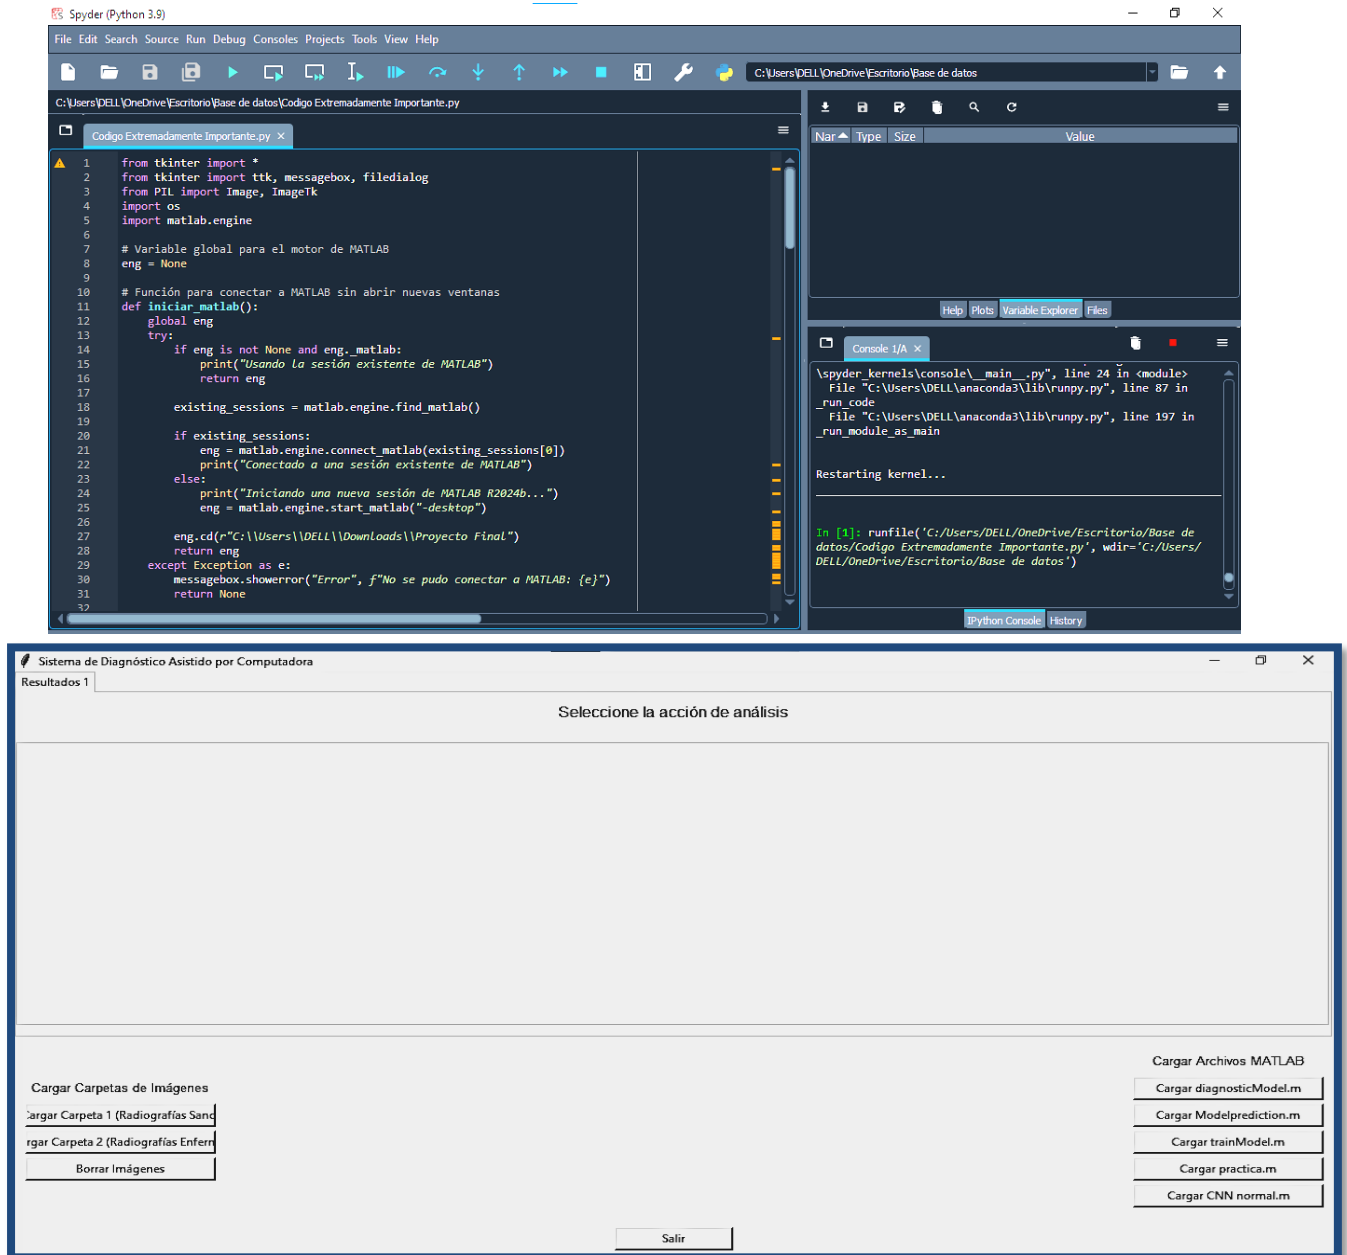


Figura 14. Interfaz De Python Amigable.

Proyecto Final

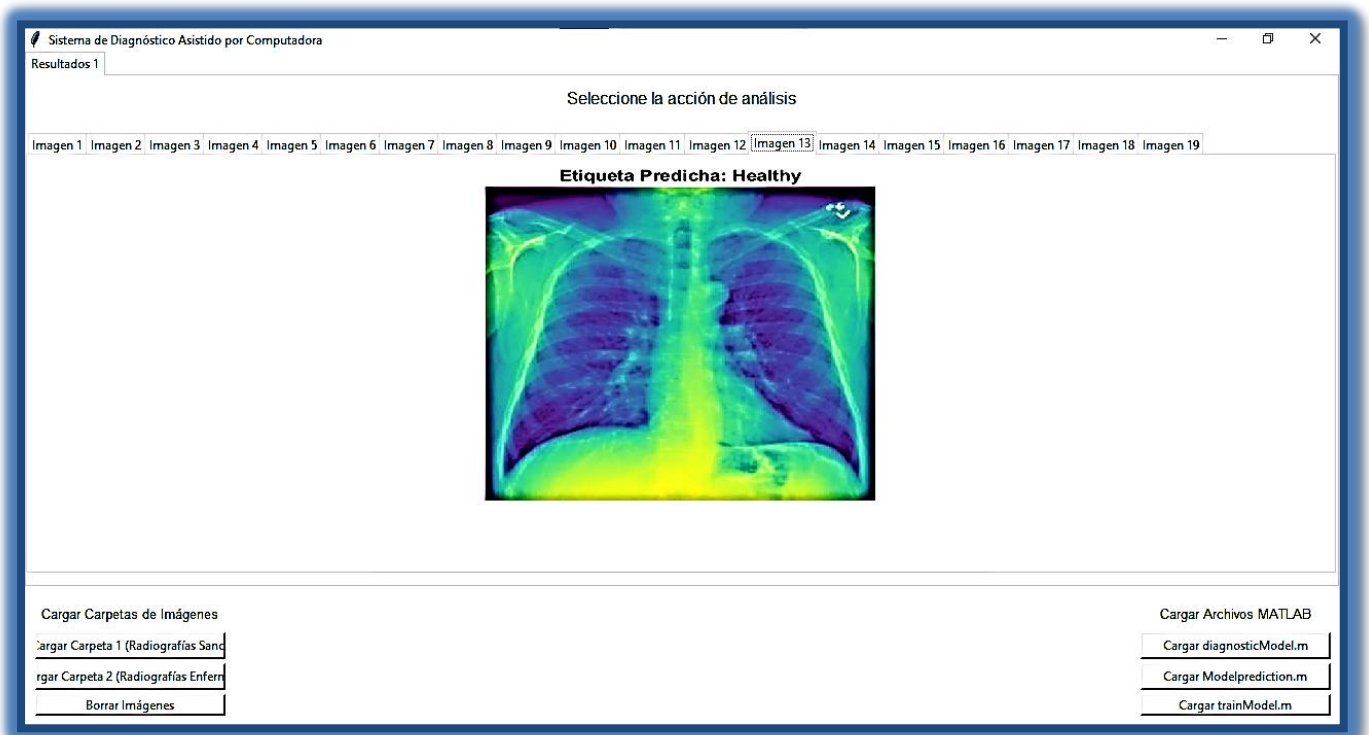
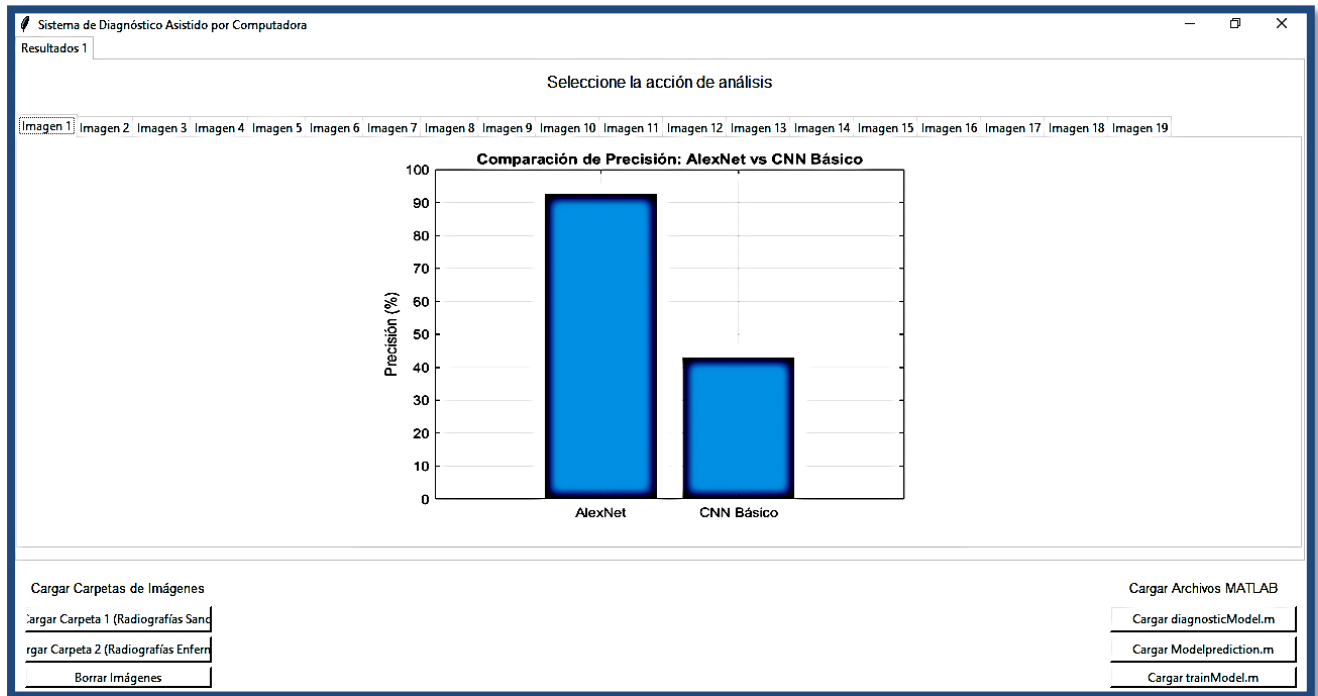


Figura 15. Interfaz De Python resultados en la interfaz (abajo), (arriba) las imágenes se alojan temporalmente en la carpeta TemplImages (Imágenes temporales).



```
>> trainModel
Accuracy (Validación): 92.86%
>> practica
Precisión del modelo en el entrenamiento: 92.86%
```

Imagen 1 - Etiqueta original: Normal 2
 Porcentaje de segmentación: 57.45%
 Predicción del modelo: Healthy

Imagen 2 - Etiqueta original: Pneumonia
 Porcentaje de segmentación: 58.70%
 Predicción del modelo: Unhealthy

Imágenes procesadas y guardadas en: C:/Users/DELL/Downloads/Proyecto
 Final/TempImages

Figura 16. Interfaz De Python imprime grafica de CNN normal a comparación con CNN AlexNet con resultados impresos en la consola.

Capítulo 4. Conclusiones

La implementación de redes neuronales convolucionales basadas en AlexNet para la segmentación automática de imágenes médicas alcanzó precisiones de clasificación entre 92.5% y 97.5% al trabajar con un conjunto de datos de 6000 radiografías, divididas entre pulmones sanos y con neumonía. Este enfoque utilizó exclusivamente la arquitectura de AlexNet, lo que permitió procesar imágenes y segmentar características relevantes con alta precisión.

El proceso incluyó el preprocesamiento de imágenes, el entrenamiento del modelo y la validación de los resultados. En comparación, un modelo CNN básico sin AlexNet obtuvo una precisión del 57.5%, mientras que AlexNet mostró un desempeño significativamente mejor, logrando una precisión del 92.5%. Esta comparación resalta la efectividad de AlexNet para abordar problemas complejos en el análisis de imágenes médicas.

Los resultados obtenidos muestran el potencial de esta técnica para mejorar el análisis de imágenes médicas, con aplicaciones en diagnósticos más rápidos y precisos. Para trabajos futuros, se recomienda ampliar la base de datos utilizada, explorar otras arquitecturas de redes neuronales y realizar evaluaciones en entornos clínicos reales, con el objetivo de validar aún más su aplicación práctica en el campo médico.

Referencias

- [1] Instituto Tecnológico de Tijuana. (n. d) "Misión, Visión y Valores", [En línea]. Disponible en: <https://www.tijuana.tecnm.mx/>. [Accedido: 16-oct-2024].
- [2] X. Liu, L. Wang, J. Wang, y Z. Zhang, "Deep Learning for Medical Image Segmentation: A Review," arXiv preprint arXiv:1908.00360, 2019. [Online]. Disponible en: <https://arxiv.org/abs/1908.00360>. [Último acceso: 29-sep-2024].
- [3] X. Wang, Y. Li, Z. Liu, y M. Chen, "Integrating Deep Learning with Big Data for Improved Medical Imaging," *Frontiers in Data Science*, vol. 8, pp. 1120989, 2023. [Online]. Disponible en: <https://www.frontiersin.org/articles/10.3389/fdata.2023.1120989/full>. [Último acceso: 29-Sep-2024].
- [4] Y. Zhang, H. Yang, y Q. Wu, "Advanced CNN Techniques for Lung Tumor Segmentation," *Cancers*, vol. 14, no. 21, pp. 5457, 2022. doi: <https://doi.org/10.3390/cancers14215457>. [Online]. Disponible en: <https://www.mdpi.com/2072-6694/14/21/5457>. [Último acceso: 29-Sep-2024].
- [5] Long, J., Shelhamer, E., & Darrell, T. (2015). Fully Convolutional Networks for Semantic Segmentation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 3431-3440. doi:10.1109/CVPR.2015.7298965. Disponible en: <https://ieeexplore.ieee.org/document/7298965>. [Último acceso: 29-Sep-2024].
- [6] Khalifa, A. F., & Badr, E. (2023). Deep Learning for Image Segmentation: A Focus on Medical Imaging. *Computers, Materials & Continua*, 75(1), 1995-2024. doi:10.32604/cmc.2023.035888. Disponible en: <https://doi.org/10.32604/cmc.2023.035888>. [Último acceso: 29-Sep-2024].

[7] A. V. Oppenheim, A. S. Willsky, y I. T. Young, Señales y Sistemas, 2da ed., Pearson Educación, 1997. [Último acceso: 29-sep-2024].

[8] S. Haykin y B. Van Veen, Señales y Sistemas, 2da ed., John Wiley & Sons, 2002. [Último acceso: 29-sep-2024].

[9] J. G. Proakis y D. G. Manolakis, Tratamiento Digital de Señales, 4ta ed., Prentice Hall, 2006. [Último acceso: 29-sep-2024].

[10] A. V. Oppenheim y R. W. Schafer, Tratamiento Digital de Señales, 3ra ed., Prentice Hall, 2010. [Último acceso: 29-sep-2024].

[11] R. E. Ziemer, W. H. Tranter, y D. R. Fannin, Señales y Sistemas: Continuos y Discretos, 4ta ed., Prentice Hall, 1998. [Último acceso: 29-sep-2024].

[12] C. M. Rader, "Discrete Fourier transforms when the number of data samples is prime," Proc. IEEE, vol. 56, no. 6, pp. 1107-1108, 1968. [Último acceso: 29-sep-2024].

[13] S. K. Mitra, Digital Signal Processing: A Computer-Based Approach, 4ta ed., McGraw-Hill, 2011. [Último acceso: 29-sep-2024].

[14] E. C. Ifeachor y B. W. Jervis, Digital Signal Processing: A Practical Approach, 2da ed., Prentice Hall, 2002. [Último acceso: 29-sep-2024].

[15] R. Lyons, Understanding Digital Signal Processing, 3ra ed., Prentice Hall, 2010. [Último acceso: 29-sep-2024].

[16] O. M. Solomon, Digital Signal Processing: Principles, Algorithms, and Applications, 4ta ed., Prentice Hall, 2007. [Último acceso: 29-sep-2024].

- [17] L. R. Rabiner y B. Gold, Theory and Application of Digital Signal Processing, Prentice Hall, 1975. [Último acceso: 29-sep-2024].
- [18] A. Krizhevsky, I. Sutskever, y G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," en Advances in Neural Information Processing Systems, 2012, pp. 1097-1105. [Último acceso: 29-sep-2024].
- [19] Y. LeCun, Y. Bengio, y G. Hinton, "Deep learning," Nature, vol. 521, no. 7553, pp. 436-444, 2015. [Último acceso: 29-sep-2024].
- [20] The MathWorks, Inc., "Deep Learning Toolbox," MATLAB Documentation, 2024. [En línea]. Disponible en: <https://www.mathworks.com/help/deeplearning/>. [Último acceso: 27-nov-2024].
- [21] F. Chollet, "Keras: The Python Deep Learning library," 2024. [En línea]. Disponible en: <https://keras.io>. [Último acceso: 27-nov-2024].
- [22] P. T. Mooney, "Chest X-Ray Images (Pneumonia)," Kaggle Dataset, [En línea]. Disponible en: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia/data>. [Último acceso: 12-dic-2024].
- [23] J. Cohen, "COVID-19 Radiography Database," Mendeley Data, vol. 2, [En línea]. Disponible en: <https://data.mendeley.com/datasets/rscbjbr9sj/2>. [Último acceso: 12-dic-2024].
- [24] T. S. Rajpurkar, "CheXpert: A Large Chest X-Ray Dataset," Mendeley Data, vol. 1, [En línea]. Disponible en: <https://data.mendeley.com/datasets/dvntn9yhd2/1>. [Último acceso: 12-dic-2024].

[25] H. Kermany et al., "Chest X-Ray Deep Learning for Pneumonia Detection," PubMed Central, vol. PMC10252226, 2024. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10252226/>. [Último acceso: 12-dic-2024].

[26] M. Traoré, "Chest X-Ray Dataset (Mendeley)," Mendeley Data, vol. 1, [En línea]. Disponible en: <https://data.mendeley.com/datasets/m4s2jn3csb/1>. [Último acceso: 12-dic-2024].

[27] M. Traoré, "Chest X-Rays - Universe Roboflow," Roboflow Universe, [En línea]. Disponible en: <https://universe.roboflow.com/mohamed-traore-2ekkp/chest-x-rays-qjmia>. [Último acceso: 12-dic-2024].

Anexos

- A.1 Enlace de GitHub con los códigos en Python y Matlab los códigos de Matlab se pueden ejecutar solamente con una licencia de paga con el Toolbox Deep Learning.
<https://github.com/Detsro/Residencia-Profesional.git>