



TECNOLÓGICO
NACIONAL DE MÉXICO



“SEGMENTACIÓN AUTOMÁTICA DE IMÁGENES CON APRENDIZAJE PROFUNDO”

INSTITUTO TECNOLÓGICO DE TIJUANA
DEPARTAMENTO DE INGENIERÍA ELÉCTRICA Y ELECTRÓNICA
INGENIERÍA BIOMÉDICA

Residencia Profesional

ALUMNO: **MERAZ GALEANA MAURICIO JESÚS**

NO. DE CONTROL: 18210139

ESPECIALIDAD: TECNOLOGÍAS BIOMÉDICAS APLICADAS

ASESOR INTERNO: M.C. FORTUNATO RAMÍREZ ARZATE

ASESOR EXTERNO: FERNANDO ARMANDO VILLALBAZO

17/Enero/2025

Índice

Capitulo 1 . Introducción.

Antecedentes.

Planteamiento del problema.

Delimitación.

Hipótesis.

1.1 Descripción De la Institución y proyecto de investigación.

1.2 Objetivos.

1.2.1 Objetivos General.

1.2.2 Objetivos Específicos.

1.3 Justificación.

Metodología.

Capitulo 2 . Marco Teórico.

2.1 Teorema de muestreo.

2.2 Señales periódicas discretas en el tiempo.

2.3 señales no periódicas: (TFD).

2.4 Propiedades de la TDF Y TFTD.

2.5 Análisis de sistemas lineales invariantes en el tiempo discreto.

2.6 Algoritmo de la FFT.

2.7 Sistemas discretos y transformada Z.

2.8 Propiedades de la transformada Z.

2.9 Transformada Z inversa

2.10 Función de transferencia

2.11 Análisis de sistemas discretos LIT con transformada Z

2.12 Deep learning.

2.13 Redes convolucionales (CNN).

2.14 AlexNet.

2.15 Matlab.

2.16 Python.

Capítulo 3. Desarrollo y Resultados.

3.1 Ejecución de las herramientas a utilizar.

3.1.1 Preprocesamiento de imágenes.

3.1.2 Implementación de la TFD.

3.1.3 Aplicación de la transformada Z y su inversa.

3.2 Uso de AlexNet Para la extracción

de características.

3.2.1 Entrenamiento y validación del Clasificador.

3.2.2 Evaluación de la segmentación de imágenes.

3.2.3 Comparación de métodos tradicionales y Deep learning.

3.3 Resultados experimentales.

Capítulo 4. Conclusiones.

Trabajos a Futuro.

Referencias.

Capítulo 1. Introducción

Antecedentes

Estado del Arte

Área de Oportunidad

Las redes neuronales convolucionales (CNN) han transformado la segmentación de imágenes médicas al superar las limitaciones de los métodos manuales. Ofrecen mayor precisión y eficiencia, optimizando el análisis de grandes volúmenes de datos. Este avance es clave en diagnósticos médicos rápidos y confiables.

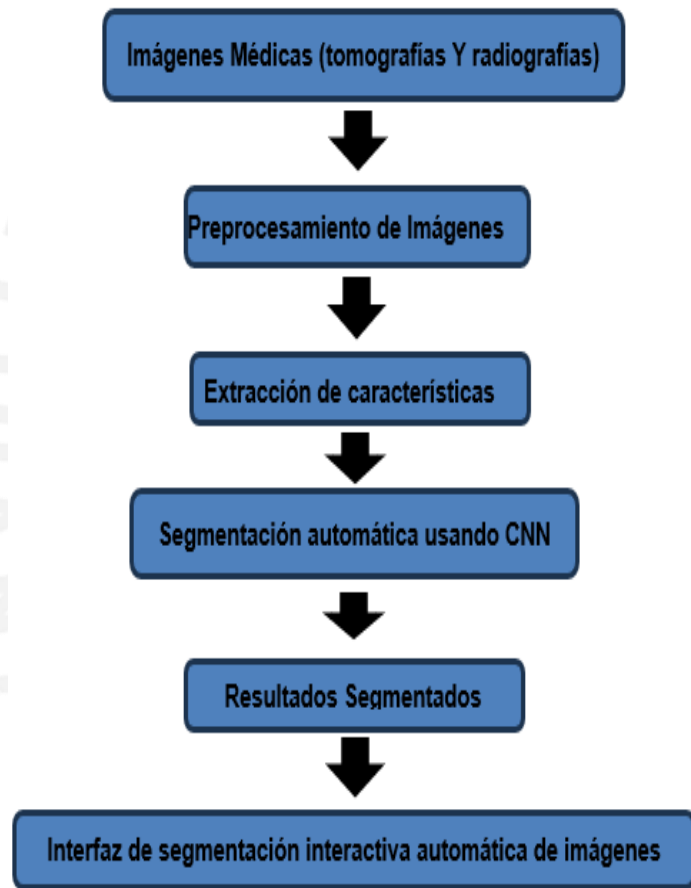
Estudios recientes validan el uso de CNN en segmentación médica. Liu et al. (2019) destacaron su eficacia en identificar estructuras anatómicas complejas. Zhang et al. (2022) demostraron que las CNN pueden segmentar tumores pulmonares con alta precisión. Wang et al. (2023) subrayó la importancia del aprendizaje profundo para extraer patrones relevantes.

El aumento de datos médicos requiere herramientas automatizadas para análisis rápidos. Este proyecto, basado en AlexNet, mejora la precisión y eficiencia, beneficiando con diagnósticos más rápidos y confiables.

Planteamiento del problema

El problema radica en que la segmentación manual de imágenes médicas es lenta, propensa a errores y no eficiente frente al volumen creciente de datos.

Los métodos tradicionales carecen de la precisión y velocidad necesarias. Se propone una solución automatizada con AlexNet, mejorando la rapidez y exactitud del diagnóstico médico.



Instituto Tecnológico
de Tijuana

Figura 1. Diagrama de flujo del planteamiento de problemas

Adaptado de: M. J. Meraz Galeana, "Segmentación automática de imágenes con aprendizaje profundo", Residencia Profesional, Instituto Tecnológico de Tijuana, 2025.

Delimitación

- a) El proyecto se desarrollará en el Instituto Tecnológico de Tijuana durante un periodo de seis meses.
- b) Se enfocará en la segmentación de tomografías computarizadas y radiografías utilizando AlexNet, excluyendo resonancias magnéticas y ultrasonidos.
- c) Se trabajará con una base de datos de 6000 imágenes de pacientes con diferentes condiciones pulmonares.
- d) La aplicación será desarrollada y evaluada en Matlab y Python, sin utilizar infraestructura externa.



Hipótesis

La implementación de redes neuronales convolucionales (CNN), específicamente el modelo AlexNet, puede superar significativamente los métodos tradicionales de segmentación de imágenes médicas. Esto mejora tanto la precisión como la eficiencia en el análisis de imágenes, permitiendo una segmentación más exacta de características relevantes en radiografías, optimizando el diagnóstico médico al reducir el tiempo de análisis y aumentar la fiabilidad de los resultados.

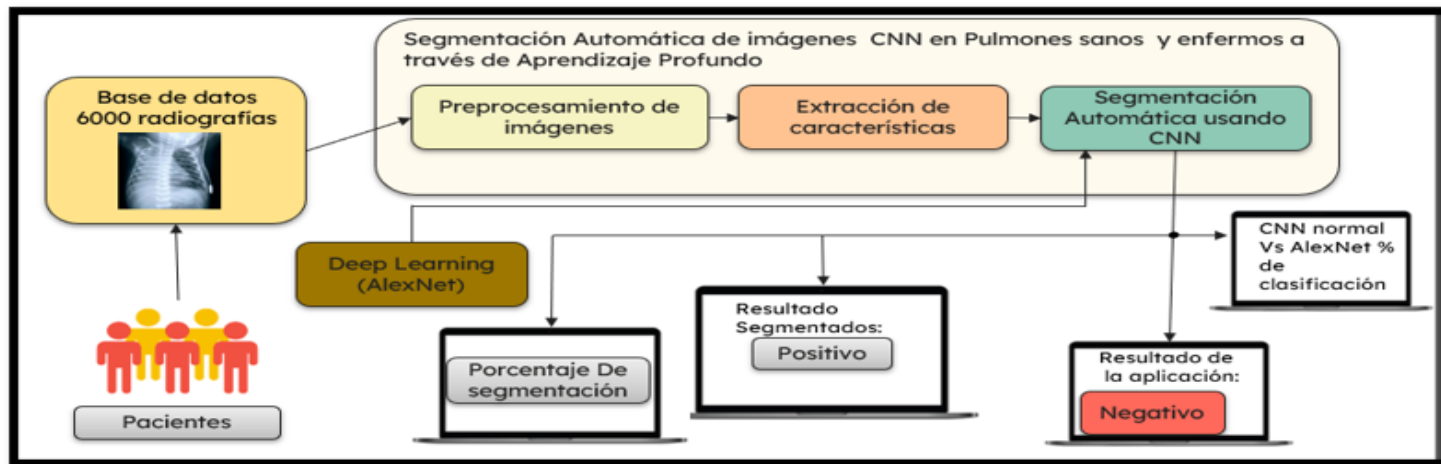


Figura 2. Diagrama de bloques de resultados esperados. Adaptado de: M. J. Meraz Galeana, "Segmentación automática de imágenes con aprendizaje profundo", Residencia Profesional, Instituto Tecnológico de Tijuana, 2025.

1.1 Descripción de la institución y proyecto de investigación

El Instituto Tecnológico de Tijuana (ITT) es una institución líder en educación tecnológica en Baja California, comprometida con la calidad y la mejora continua. Este proyecto de Residencia Profesional se desarrolla en el Departamento de Ingeniería Eléctrica y Electrónica, como parte del programa de Ingeniería Biomédica. Su objetivo es implementar un sistema avanzado de segmentación automática de imágenes médicas utilizando AlexNet, mejorando el diagnóstico de patologías pulmonares. Los resultados también apoyan el proyecto "Plataforma de Diagnóstico Asistido por Computadora", fortaleciendo la innovación tecnológica en telemedicina.



Instituto Tecnológico
de Tijuana

Figura 3. Pulmón sano. H. Kermany et al., "Chest X-Ray Deep Learning for Pneumonia Detection," PubMed Central, vol. PMC10252226, 2024. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10252226/>. [Último acceso: 01-ene-2025].

Capítulo 1.2 Objetivos

1.2.1 Objetivo general

Desarrollar un algoritmo para la segmentación automática de imágenes médicas utilizando técnicas de aprendizaje profundo, específicamente redes neuronales convolucionales (CNN) basadas en el modelo AlexNet.



Instituto Tecnológico
de Tijuana

1.2 Objetivos

1.2.2 Objetivos específicos

1. Implementar un sistema de preprocesamiento de imágenes que optimice la calidad de las tomografías y radiografías, preparándolas para una segmentación precisa y eficiente.
2. Desarrollar y optimizar un algoritmo de segmentación automática basado en AlexNet, que identifique y segmente características relevantes en imágenes médicas con alta precisión.
3. Comparar la precisión, a través de pruebas comparativas con métodos tradicionales y aprendizaje profundo, utilizando un conjunto de datos de 6000 imágenes para garantizar su eficacia.



Instituto Tecnológico
de Tijuana

1.3 Justificación

1. La segmentación manual de imágenes, como tomografías y radiografías, es un proceso que consume mucho tiempo y es propenso a errores, afectando la calidad del análisis y tratamiento de los pacientes.
2. La creciente demanda de métodos más precisos y eficientes en hospitales y centros de investigación resalta la necesidad de soluciones automatizadas.
3. Estudios recientes, como los de Liu et al. (2019), han demostrado que el uso de redes neuronales convolucionales (CNN), como AlexNet, mejora significativamente la precisión en la segmentación al identificar patrones complejos en grandes volúmenes de datos.
4. La automatización en la segmentación de imágenes impulsará la investigación y el desarrollo de nuevas terapias, contribuyendo al avance del cuidado de la salud.



Fase 1 Implementación de Preprocesamiento de imágenes

- a) Se mejorará la calidad de las tomografías y radiografías mediante técnicas de normalización, filtrado y segmentación inicial.
- b) Estas preparaciones optimizarán las imágenes para su entrada en el modelo AlexNet.

Fase 2 Desarrollo de algoritmos de segmentación automática

- a) Se configurará y entrenará AlexNet para identificar características relevantes en las imágenes, ajustando los parámetros para optimizar la precisión.
- b) El rendimiento del modelo será evaluado y mejorado iterativamente para asegurar su eficacia en la segmentación.

Fase 3 Comparaciones de diferentes algoritmos de aprendizaje sistema

- a) Se comparan y clasifican diferentes algoritmos el rendimiento del modelo matemático basado en AlexNet, CNN Y SVM con métodos tradicionales .
- b) Los resultados serán documentados y el Modelo de aprendizaje será ajustado según los hallazgos obtenidos en las pruebas.

2.1 Teorema de Muestreo:

El teorema de Nyquist-Shannon establece que una señal continua puede representarse completamente si se muestrea a una tasa superior al doble de su máxima frecuencia. [1].

2.2 Señales periódicas discretas:

La TDF analiza señales repetitivas en el dominio de frecuencia. [2].

2.3 Señales no periódicas:

La TDF y TFTD descomponen señales en componentes de frecuencia para su análisis. [3].

2.4 Propiedades de la TFD Y TFTD:

Incluyen linealidad, convolución y simetría, esenciales para procesamiento digital. [4].

2.4 Sistemas Lineales invariantes en el Tiempo:

Analizan la respuesta de sistemas discretos usando convoluciones. [5].

2.6 Algoritmo de la FFT:

Calcula eficientemente la TDF en grandes conjuntos de datos. [6].

2.7 Sistemas Discretos y Transformada Z:

Transforma señales al dominio de frecuencia compleja para su análisis. [7].

2.8 Propiedades de la Transformada Z:

Incluyen linealidad y desplazamiento en el

tiempo, útiles en señales discretas. [8].

2.9 Transformada Z Inversa:

Recupera señales originales desde el dominio Z. [9].

2.10 Función de Transferencia:

Relaciona entrada y salida en sistemas discretos para analizar su estabilidad. [10].

2.11 Análisis de Sistemas Discretos LIT:

Evalúa la respuesta en frecuencia y estabilidad de sistemas discretos. [11].

2.12 Deep Learning:

Emplea redes profundas para procesar grandes volúmenes de datos. [12].

2.13 Redes Neuronales

Convolucionales (CNN):

Procesan datos como imágenes ,extrayendo características relevantes. [13].

2.14 AlexNet:

Modelo de CNN destacado por su precisión en clasificación y segmentación. [14].

2.15 MATLAB:

Software con herramientas avanzadas para diseñar y entrenar redes neuronales. [14].

2.16 PYTHON:

Ofrece biblioteca potentes como Tensor Flow para Deep Learning. [15].

3.1 Ejecución de las herramientas a utilizar

- a) Se mejorará la calidad de las radiografías mediante técnicas de normalización, filtrado y segmentación inicial con una base de datos de 6000 radiografías.
- b) Estas preparaciones optimizarán las imágenes para su entrada en el modelo AlexNet.

Tabla 1. Ejemplos de pulmones normal (izquierda) y de pulmones con neumonía(derecha).




Tabla 1. Ejemplos de pulmones normales (izquierda) y de pulmones con neumonía (derecha)

[23]. J. Cohen, "COVID-19 Radiography Database," Mendeley Data, vol. 2, [En línea]. Disponible en:

<https://data.mendeley.com/datasets/rschbjbr9sj/2>. [Último acceso: 10-ene-2025].

3.1.1 Preprocesamiento de Imágenes

- a) Las radiografías utilizadas se redimensionaron a 227x227 píxeles y se convirtieron a formato RGB para cumplir las especificaciones de entrada de AlexNet optimizando las características necesarias para el análisis (ejemplo figura 4).

3.1.2 Implementación de la transformada de fourier discreta (TDF)

a) La TDF descompuso las imágenes en frecuencias, identificando patrones y reduciendo ruido para segmentar áreas clave (figura 5).




Figura 5. Descomposición de imagen de Matlab en TFD utilizada en el proyecto de segmentación de imágenes.

Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en:

<https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025].




Figura 4. Arquitectura de AlexNet utilizada en el proyecto de segmentación de imágenes. Fuente: Meraz Galeana, M. J., Residencia profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-profesional>. [Último acceso: 17 de enero de 2025].

3.1.3 Aplicación de la transformada Z y su Inversa

- a) La transformada Z se utilizó para analizar señales discretas en el dominio de la frecuencia y luego la transformada z inversa permite reconstruir las imágenes procesadas validando los resultados en el dominio de la frecuencia.

```
% Transformada Z inversa utilizando IFFT  
Y = ifft2(X);  
% Visualización de la Transformada Z Inversa  
figure;  
imshow(abs(Y), []);  
title(['Transformada Z Inversa - Imagen ', num2str(idc)]);
```

Figura 6 líneas de código en Matlab de transformada Z utilizada en el proyecto de segmentación de imágenes. Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025].

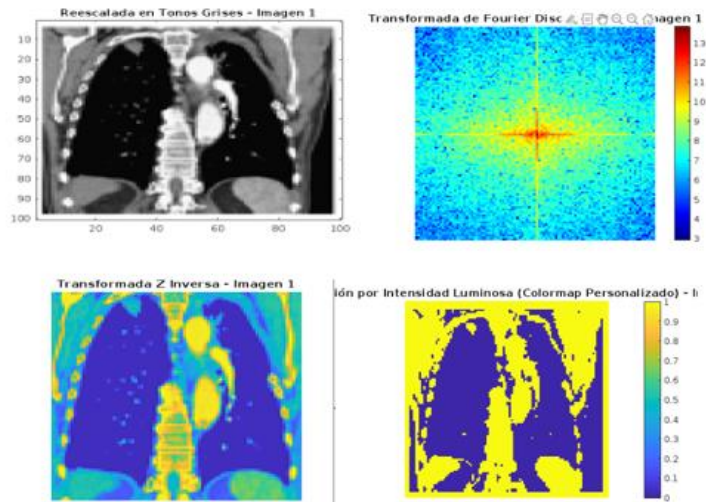


Figura 7 Imagen en Matlab de transformada Z y su inversa utilizada en el proyecto de segmentación de imágenes. Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025].

3.2 Uso de AlexNet para la extracción de características

Se utilizó AlexNet, una red neuronal preentrenada, para extraer características de imágenes en la capa fc7. Estas características sirvieron para entrenar un clasificador SVM que distinguiera entre pulmones sanos y afectados todo ese muestra en la figura 8.

```
% Cargar la red preentrenada AlexNet
net = alexnet;
% Obtener las capas necesarias para la extracción de características
featureLayer = 'fc7';
% Extraer características de las imágenes preprocesadas usando AlexNet
features = activations(net, preprocessedImages, featureLayer, 'MiniBatchSize', 32,
'OutputAs', 'rows');
```

Figura 8 líneas de código de Matlab Trainmodel.m AlexNet utilizada en el proyecto de segmentación de imágenes. Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025].

3.2.1 Entrenamiento y validación del clasificador

El modelo CNN fue entrenado utilizando un conjunto de datos balanceado, dividiéndolo en subconjuntos de entrenamiento y prueba se observa en la figura 9. Los datos de validación demostraron una precisión del 92%, lo que resalta la efectividad de la metodología propuesta.

```
% Dividir los datos en conjuntos de entrenamiento y validación
cv = cvpartition (labels, 'HoldOut', 0.2);
trainIdx = training(cv);
testIdx = test(cv);
% Entrenar un clasificador SVM con las características extraídas
classifier = fitsvm(features(trainIdx, :), labels(trainIdx));
% Evaluar el clasificador
predictedLabels = predict(classifier, features(testIdx, :));
accuracy = sum(predictedLabels == labels(testIdx)) / numel(predictedLabels);
fprintf('Accuracy: %.2f%%\n', accuracy * 100);
% Guardar el modelo entrenado
save('diagnosticModel.mat', 'classifier');
```

Figura 9. líneas de código de Matlab Trainmodel.m AlexNet utilizada en el proyecto de segmentación de imágenes. Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025].



3.2.2 Evaluación de segmentación de imágenes

Se implementó una técnica de umbralización automática para segmentar áreas de interés dentro de las imágenes en la Figura 10 se muestra. Este enfoque permitió resaltar características específicas, como anomalías pulmonares, con gran precisión.

Imagen Filtrada con Filtro Pasa Bajas - Imagen 2




Figura 10 Segmentación de imagen en Matlab utilizada en el proyecto de segmentación de imágenes.

Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025].

3.2.3 Comparación de métodos tradicionales y Deep learning

Aspecto	Métodos Tradicionales	Deep Learning (AlexNet)	Combinación
Base de funcionamiento	Uso de técnicas matemáticas como transformadas (Fourier, Wavelet).	Redes neuronales convolucionales (CNN) que aprenden características automáticamente.	Preprocesamiento con métodos tradicionales y clasificación con AlexNet.
Ventajas	<ul style="list-style-type: none"> -Procesamiento rápido. -Interpretación matemática clara. -Ideal para datos simples. 	<ul style="list-style-type: none"> Capacidad para manejar grandes volúmenes de datos. -Detecta patrones complejos. - Alta precisión. 	<ul style="list-style-type: none"> - Reduce ruido y optimiza datos. - Mejora precisión y eficiencia. - Maximiza la robustez del sistema.
Limitaciones	<ul style="list-style-type: none"> - Difícil manejo de datos complejos o con ruido. -Depende de parámetros diseñados manualmente. 	<ul style="list-style-type: none"> - Requiere gran poder computacional. -Necesidad de datos extensos para entrenamiento. - Requiere mejor procesador. 	<ul style="list-style-type: none"> -Complejidad del sistema. - Mayor necesidad de integración y ajuste de precisión. - Necesidad de un mejor filtro de preprocesamiento.
Aplicación en los códigos	Preprocesamiento con transformadas y funciones definidas.	Uso de AlexNet para extraer características y clasificar imágenes.	Preprocesamiento con transformadas y clasificación con AlexNet.

Tabla 2. Métodos Tradicionales vs Deep Learning (AlexNet) y su Combinación. utilizada en el proyecto de segmentación de imágenes. Fuente: Meraz Galeana, M. J., Residencia Profesional, Repositorio GitHub, 2025. [En línea]. Disponible en: <https://github.com/Detsro/Residencia-Profesional>. [Último acceso: 17 de enero de 2025]..



3.3 Resultados Experimentales

- a) Se desarrollará una aplicación accesible con una interfaz intuitiva, adecuada para profesionales de la salud.

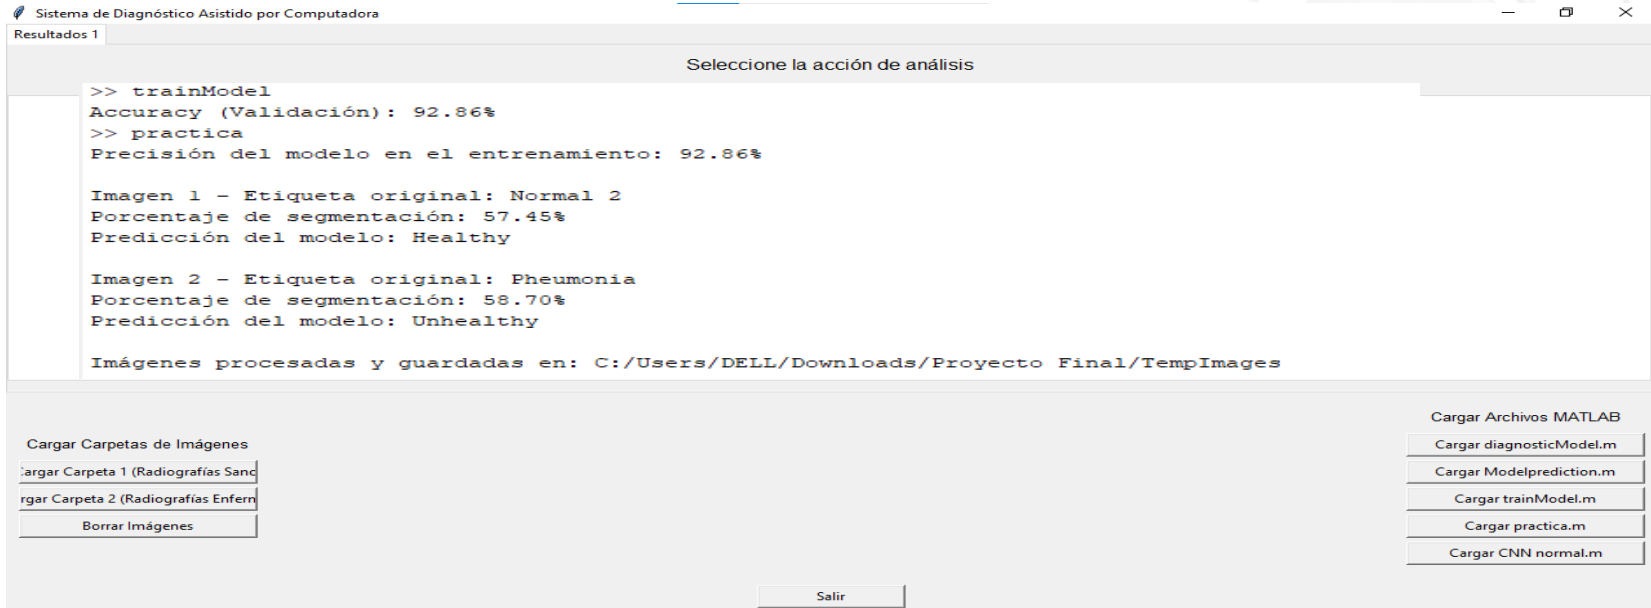


Figura 11. Interfaz de python amigable Adaptado de: M. J. Meraz Galeana, "Segmentación automática de imágenes con aprendizaje profundo", Residencia Profesional, Instituto Tecnológico de Tijuana, 2024.

3.3 Resultados experimentales

Sistema de Diagnóstico Asistido por Computadora

Resultados 1

Seleccione la acción de análisis

Imagen 1 | Imagen 2 | Imagen 3 | Imagen 4 | Imagen 5 | Imagen 6 | Imagen 7 | Imagen 8 | Imagen 9 | Imagen 10 | Imagen 11 | Imagen 12 | Imagen 13 | Imagen 14 | Imagen 15 | Imagen 16 | Imagen 17 | Imagen 18 | Imagen 19

Etiqueta Predicha: Healthy



Cargar Carpetas de Imágenes

Cargar Carpeta 1 (Radiografías Sano)

Cargar Carpeta 2 (Radiografías Enfermo)

Borrar Imágenes

Cargar Archivos MATLAB

Cargar diagnosticModel.m

Cargar Modelprediction.m

Cargar trainModel.m

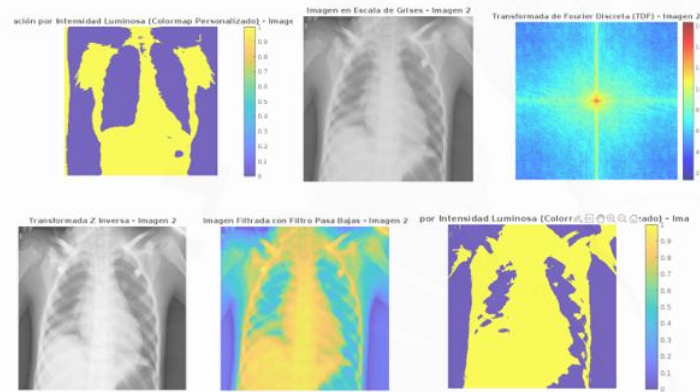



Figura 11: Segmentación de imágenes en Matlab de un pulmón sano y pulmón enfermo Con clasificador CNN 95% de precisión.

Sistema de Diagnóstico Asistido por Computadora

Resultados 1

Seleccione la acción de análisis

Imagen 1 | Imagen 2 | Imagen 3 | Imagen 4 | Imagen 5 | Imagen 6 | Imagen 7 | Imagen 8 | Imagen 9 | Imagen 10 | Imagen 11 | Imagen 12 | Imagen 13 | Imagen 14 | Imagen 15 | Imagen 16 | Imagen 17 | Imagen 18 | Imagen 19



Cargar Carpetas de Imágenes

Cargar Carpeta 1 (Radiografías Sano)

Cargar Carpeta 2 (Radiografías Enfermo)

Borrar Imágenes

Cargar Archivos MATLAB

Cargar diagnosticModel.m

Cargar Modelprediction.m

Cargar trainModel.m



Figura 12,13,14. Interfaz de python amigable ejecutándose Adaptado de: M. J. Meraz Galeana, "Segmentación automática de imágenes con aprendizaje profundo", Residencia Profesional, Instituto Tecnológico de Tijuana, 2024.

Capítulo 4 . Conclusiones

La implementación de redes neuronales convolucionales basadas en AlexNet para la segmentación automática de imágenes médicas alcanzó precisiones de clasificación entre 92.5% y 97.5% al trabajar con un conjunto de datos de 6000 radiografías, divididas entre pulmones sanos y con neumonía. Este enfoque utilizó exclusivamente la arquitectura de AlexNet, lo que permitió procesar imágenes y segmentar características relevantes con alta precisión.

El proceso incluyó el preprocesamiento de imágenes, el entrenamiento del modelo y la validación de los resultados. En comparación, un modelo CNN básico sin AlexNet obtuvo una precisión del 57.5%, mientras que AlexNet mostró un desempeño significativamente mejor, logrando una precisión del 92.5%. Esta comparación resalta la efectividad de AlexNet para abordar problemas complejos en el análisis de imágenes médicas.

Trabajos A Futuro

Se propone integrar arquitecturas más avanzadas, como ResNet, para mejorar la precisión en la segmentación y expandir la base de datos con imágenes de diversas modalidades médicas. Además, se recomienda optimizar los tiempos de procesamiento mediante el uso de hardware especializado y evaluar la interfaz en escenarios reales para mejorar su funcionalidad y usabilidad. Finalmente, sería útil desarrollar módulos que permitan la integración con herramientas biomédicas o bases de datos externas para ampliar su aplicabilidad.



Instituto Tecnológico
de Tijuana

Referencias

- [1]. Instituto Tecnológico de Tijuana. (n. d) "Misión, Visión y Valores", [En línea]. Disponible en: <https://www.tijuana.tecnm.mx/>. [Accedido: 16-oct-2024].
- [2]. X. Liu, L. Wang, J. Wang, y Z. Zhang, "Deep Learning for Medical Image Segmentation: A Review," arXiv preprint 1908.00360 arXiv:1908.00360, 2019. [Online]. Disponible en: <https://arxiv.org/abs/>. [Último acceso: 29-Sep-2024].
- [3]. X. Wang, Y. Li, Z. Liu, y M. Chen, "Integrating Deep Learning with Big Data for Improved Medical Imaging," Frontiers in Data Science, vol. 8, pp. 1120989, 2023. [Online]. Disponible en: <https://www.frontiersin.org/articles/10.3389/fdata.2023.1120989/full>. [Último acceso: 29-Sep-2024].
- [4]. Y. Zhang, H. Yang, y Q. Wu, "Advanced CNN Techniques for Lung Tumor Segmentation," Cancers, vol. 14, no. 21, pp. 5457, 2022. doi: <https://doi.org/10.3390/cancers14215457>. [Online]. Disponible en: <https://www.mdpi.com/2072-6694/14/21/5457>. [Último acceso: 29-Sep-2024].
- [5]. Long, J., Shelhamer, E., & Darrell, T. (2015). Fully Convolutional Networks for Semantic Segmentation. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 3431-3440. doi:10.1109/CVPR.2015.7298965. [Online]. Disponible en: <https://ieeexplore.ieee.org/document/7298965>. [Último acceso: 29-Sep-2024].

Referencias

- [6]. Khalifa, A. F., & Badr, E. (2023). Deep Learning for Image Segmentation: A Focus on Medical Imaging. Computers, Materials & Continua, 75(1), 1995-2024. doi:10.32604/cmc.2023.035888. Disponible en: <https://doi.org/10.32604/cmc.2023.035888>. [Último acceso: 29-Sep-2024].
- [7]. A. V. Oppenheim, A. S. Willsky, y I. T. Young, Señales y Sistemas, 2da ed., Pearson Educación, 1997. [Último acceso: 29-sep-2024].
- [8]. S. Haykin y B. Van Veen, Señales y Sistemas, 2da ed., John Wiley & Sons, 2002. [Último acceso: 29-sep-2024].
- [9]. J. G. Proakis y D. G. Manolakis, Tratamiento Digital de Señales, 4ta ed., Prentice Hall, 2006. [Último acceso: 29-sep-2024].

Referencias

[10]. A. V. Oppenheim y R. W. Schafer, Tratamiento Digital de Señales, 3ra ed., Prentice Hall, 2010. [Último acceso: 29-sep-2024].

[11]. R. E. Ziemer, W. H. Tranter, y D. R. Fannin, Señales y Sistemas: Continuos y Discretos, 4ta ed., Prentice Hall, 1998. [Último acceso: 29-sep-2024].

[12]. C. M. Rader, "Discrete Fourier transforms when the number of data samples is prime," Proc. IEEE, vol. 56, no. 6, pp. 1107-1108, 1968. [Último acceso: 29-sep-2024].

[13]. S. K. Mitra, Digital Signal Processing: A Computer-Based Approach, 4ta ed., McGraw-Hill, 2011. [Último acceso: 29-sep-2024].

 Instituto Tecnológico
de Baja California

[14]. E. C. Ifeachor y B. W. Jervis, Digital Signal Processing: A Practical Approach, 2da ed., Prentice Hall, 2002. [Último acceso: 29-sep-2024].

- [15]. R. Lyons, Understanding Digital Signal Processing, 3ra ed., Prentice Hall, 2010. [Último acceso: 29-sep-2024].
- [16]. O. M. Solomon, Digital Signal Processing: Principles, Algorithms, and Applications, 4ta ed., Prentice Hall, 2007. [Último acceso: 29-sep-2024].
- [17]. L. R. Rabiner y B. Gold, Theory and Application of Digital Signal Processing, Prentice Hall, 1975. [Último acceso: 29-sep-2024].
- [18]. A. Krizhevsky, I. Sutskever, y G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," en Advances in Neural Information Processing Systems, 2012, pp. 1097-1105. [Último acceso: 29-sep-2024].

Referencias

- [19]. Y. LeCun, Y. Bengio, y G. Hinton, "Deep learning," Nature, vol. 521, no. 7553, pp. 436-444, 2015. [Último acceso: 29-sep-2024].
- [20]. The MathWorks, Inc., "Deep Learning Toolbox," MATLAB Documentation, 2024. [En línea]. Disponible en: <https://www.mathworks.com/help/deeplearning/>. [Último acceso: 27-nov-2024].
- [21]. F. Chollet, "Keras: The Python Deep Learning library," 2024. [En línea]. Disponible en: <https://keras.io>. [Último acceso: 27-nov-2024].
- [22]. P. T. Mooney, "Chest X-Ray Images (Pneumonia)," Kaggle Dataset, [En línea]. Disponible en: <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia/data>. [Último acceso: 12-dic-2024].
- [23]. J. Cohen, "COVID-19 Radiography Database," Mendeley Data, vol. 2, [En línea]. Disponible en: <https://data.mendeley.com/datasets/rscbjbr9sj/2>. [Último acceso: 12-dic-2024].



- [24]. T. S. Rajpurkar, "CheXpert: A Large Chest X-Ray Dataset," Mendeley Data, vol. 1, [En línea]. Disponible en: <https://data.mendeley.com/datasets/dvntn9yhd2/1>. [Último acceso: 12-dic-2024].
- [25]. H. Kermany et al., "Chest X-Ray Deep Learning for Pneumonia Detection," PubMed Central, vol. PMC10252226, 2024. [En línea]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10252226/>. [Último acceso: 12-dic-2024].
- [26]. M. Traoré, "Chest X-Ray Dataset (Mendeley)," Mendeley Data, vol. 1, [En línea]. Disponible en: <https://data.mendeley.com/datasets/m4s2jn3csb/1>. [Último acceso: 12-dic-2024].
- [27]. M. Traoré, "Chest X-Rays - Universe Roboflow," Roboflow Universe, [En línea]. Disponible en: <https://universe.roboflow.com/mohamed-traore-2ekkp/chest-x-rays-qjmia>. [Último acceso: 12-dic-2024].

